

SAVIA — Sistema Ambiental de Vigilancia con IA

Brayan Osorio
Pavel Ramírez
Brian Acevedo
Carolina Ramírez

Sistema de priorización de cuencas en Caquetá basado en datos abiertos, análisis de cascada topológica hidrológica e inteligencia artificial. SAVIA cruza deforestación acumulada aguas arriba con infraestructura hídrica expuesta para identificar cuencas de riesgo combinado, siguiendo la validación retrospectiva del evento Caquetá 2020-2022 solicitada por el reto.

COLOMBIA
2026

Introducción	4
1. Presentación general del proyecto	5
1.1. Resumen ejecutivo	5
1.2. Identificación del equipo y categoría de participación	5
1.3. Alineación con el Concurso Datos al Ecosistema 2026	5
2. Comprensión del problema	7
2.1. Contexto ambiental de Colombia	7
2.2. Problema público central	7
2.3. Pregunta de negocio o pregunta orientadora	7
2.4. Justificación del proyecto	8
3. Objetivos y alcance	9
3.1. Objetivo general	9
3.2. Objetivos específicos	9
3.3. Alcance funcional	9
3.4. Alcance técnico	9
4. Usuarios, beneficiarios y casos de uso	11
4.1. Stakeholders principales	11
4.2. Casos de uso prioritarios	11
5. Fuentes de datos abiertos	12
5.1. Estrategia general de datos	12
5.2. Fuente principal hídrica: IDEAM ICA	12
5.3. Fuentes principales del módulo forestal: Hansen GFC, HydroSHEDS y SINCHI	12
5.4. Fuentes territoriales y de referencia: DIVIPOLA, SMBYC e Inventario Forestal Nacional	12
5.5. Fuentes complementarias ambientales e institucionales	13
5.6. Licencias, trazabilidad y atribución de datos	13
6. Preparación, integración y calidad de datos	14
6.1. Flujo de preparación del módulo forestal	14
6.2. Flujo de preparación del módulo hídrico	14
6.3. Criterios de calidad de datos	14
6.4. Diccionario de datos y metadatos	14
7. Arquitectura de la solución	16
7.1. Visión general de arquitectura	16
7.2. Herramientas tecnológicas	16
7.3. Repositorio y estructura técnica del proyecto	16
8. Metodología de inteligencia artificial	17
8.1. Enfoque general de IA	17
8.2. Modelo de deforestación	17
8.2.1. Objetivo del módulo	17
8.2.2. Área piloto y escalabilidad nacional	17

8.2.3. Generación de alertas forestales	18
8.2.4. Métricas del módulo forestal	18
8.3. Modelo de predicción de calidad del agua	18
8.4. Modelo de detección de anomalías hídricas	18
8.4.1.1. Objetivo del módulo	19
8.4.1.2. Selección de estaciones y cuencas	19
8.4.2. Predicción de deterioro hídrico	19
8.4.3. Detección de anomalías hídricas	19
9. Validación retrospectiva	20
9.1. Propósito de la validación	20
9.2. Diseño metodológico de la validación	20
9.3. Métricas de validación retrospectiva	20
10. Dashboard y experiencia de usuario	21
10.1. Objetivo del dashboard	21
10.2. Vistas principales del tablero	21
10.3. Trazabilidad de hallazgos	21
10.4. Reportes por territorio	21
11. Evaluación técnica del sistema	22
11.1. Métricas del modelo forestal	22
11.2. Métricas del modelo hídrico	22
11.3. Limitaciones de evaluación	22
12. Impacto, escalabilidad e innovación	23
12.1. Impacto ambiental esperado	23
12.2. Impacto social e institucional	23
12.3. Escalabilidad nacional	23
12.4. Innovación del proyecto	23
13. Ética, legalidad y uso responsable	24
13.1. Principios éticos	24
13.2. Cumplimiento de licencias y derechos de autor	24
13.3. Comunicación responsable de alertas	24
14. Reproducibilidad y publicación abierta	25
14.1. Publicación del repositorio	25
14.2. Guía de reproducción	25
14.3. Documentación CRISP-ML	25
15. Resultados esperados y evidencias de entrega	26
15.1. Entregables técnicos	26
15.2. Entregables para el jurado	26
15.3. Criterios de éxito del proyecto	26

Introducción

Colombia es uno de los 17 países megadiversos del planeta y alberga aproximadamente el 10% de la biodiversidad mundial. Esta riqueza, sin embargo, convive con dos amenazas ambientales que avanzan de manera simultánea y persistente: la pérdida acelerada de cobertura boscosa, particularmente en la región amazónica, y el deterioro de la calidad del agua en cuencas hidrográficas estratégicas para el abastecimiento humano, la actividad productiva y la estabilidad ecosistémica del territorio. Solo en 2024, según el Sistema de Monitoreo de Bosques y Carbono del IDEAM, el país perdió 113.608 hectáreas de bosque natural, con cuatro departamentos del Arco Amazónico (Caquetá, Meta, Guaviare y Putumayo) concentrando casi el 70% del fenómeno. En paralelo, múltiples corrientes superficiales monitoreadas por la Red de Referencia Nacional de Calidad del Agua presentan categorías de calidad regular o mala según el Índice de Calidad del Agua, evidenciando una presión sostenida sobre el recurso hídrico.

Frente a este panorama, Colombia cuenta con una infraestructura considerable de datos abiertos ambientales. El IDEAM publica series de calidad del agua y catálogo de estaciones en datos.gov.co, el Sistema de Monitoreo de Bosques y Carbono produce reportes trimestrales y anuales, el proyecto Hansen Global Forest Change ofrece mapas raster globales de pérdida forestal con resolución de 30 metros, HydroSHEDS provee la cartografía hidrológica de referencia mundial y el SINCHI documenta la deforestación específicamente en la Amazonía colombiana. El problema central no es, por tanto, la ausencia de datos, sino la dificultad estructural de convertir esa información dispersa, técnica y heterogénea en alertas oportunas, georreferenciadas y comprensibles para autoridades ambientales, comunidades, organizaciones civiles y ciudadanía. La detección oficial de eventos de deforestación o de deterioro hídrico frecuentemente ocurre meses después del hecho, lo cual limita la capacidad de respuesta institucional y reduce el margen de acción preventiva.

SAVIA — Sistema Ambiental de Vigilancia con IA — surge como respuesta concreta a esta brecha. Es una plataforma nacional de monitoreo ambiental con cobertura para todo el territorio colombiano, desarrollada por el Equipo 66 en el nivel Avanzado del Concurso Datos al Ecosistema 2026: IA para Colombia, dentro del reto de Desarrollo Sostenible y Medio Ambiente. La propuesta integra dos módulos complementarios construidos exclusivamente sobre datos abiertos oficiales y modelos de inteligencia artificial. El módulo forestal aplica análisis raster sobre Hansen Global Forest Change combinado con cuencas hidrográficas de HydroSHEDS para calcular pérdida forestal upstream por estación de monitoreo, complementado con datos vectoriales del SINCHI para la Amazonía colombiana. El módulo hídrico combina un Isolation Forest para detección de anomalías en calidad del agua superficial (NSF-WQI sobre nueve parámetros físico-químicos y microbiológicos) con un modelo LSTM para predicción del Índice de Riesgo de Calidad del Agua para Consumo Humano (IRCA) municipal, todo alimentado por datasets del IDEAM publicados en datos.gov.co. Ambos módulos convergen en un dashboard geoespacial desarrollado en Streamlit y deployado con URL pública, accesible para usuarios sin formación técnica.

El presente documento desarrolla la propuesta completa del proyecto. Inicia con la comprensión del problema público y la formulación de la pregunta orientadora, continúa con los objetivos y el alcance funcional y técnico, identifica los usuarios y casos de uso prioritarios,

documenta las fuentes de datos abiertos seleccionadas con sus licencias y atribuciones (Hansen Global Forest Change v1.12, HydroBASINS Nivel 7, Copernicus DEM GLO-30, GADM v4.1, infraestructura hídrica IGAC/OSM y datasets IDEAM), describe la arquitectura de la solución y la metodología de inteligencia artificial (análisis de grafo dirigido con networkx, score de riesgo explicable con validación de sensibilidad, Isolation Forest con contamination='auto' y test de permutación no paramétrico), expone el diseño de la validación retrospectiva sobre el evento de deforestación en Caquetá 2020-2022 solicitado por el reto GovCamp

1. Presentación general del proyecto

1.1. Resumen ejecutivo

SAVIA es un sistema de priorización de cuencas hidrográficas en Caquetá que combina datos abiertos, análisis de cascada topológica hidrológica e inteligencia artificial para identificar zonas con mayor riesgo combinado de deforestación acumulada aguas arriba, infraestructura hídrica expuesta y pendiente del terreno. Desarrollado por el Equipo 66 en el nivel Avanzado del Concurso Datos al Ecosistema 2026: IA para Colombia, dentro del reto de Desarrollo Sostenible y Medio Ambiente, el sistema adopta explícitamente un enfoque de profundidad sobre amplitud: en lugar de una cobertura nacional superficial, se prioriza un análisis riguroso sobre Caquetá como caso de estudio, en línea con la validación retrospectiva del evento de deforestación 2020-2022 solicitada por el reto. El sistema opera sobre 44 cuencas HydroBASINS Nivel 7 aisladas dentro del departamento del Caquetá y aporta cuatro componentes analíticos coordinados. El primero es una cascada topológica construida como grafo dirigido en networkx que enruta la pérdida forestal aguas abajo mediante el atributo NEXT_DOWN, permitiendo cuantificar la deforestación acumulada de todas las cuencas ancestro que drenan hacia una cuenca dada; la cuenca con mayor cascada acumula 277.636 hectáreas provenientes de 34 cuencas aguas arriba. El segundo es un score de riesgo explicable que combina cascada de deforestación reciente e infraestructura hídrica expuesta (2 features ortogonales tras auditoría de colinealidad, con pesos 0.6/0.4 validados mediante grilla de sensibilidad y coincidencia top-10 del 67 al 100%). El tercero es un Isolation Forest configurado con contamination='auto' (umbral del paper original de Liu et al. 2008) más prueba de sensibilidad documentada (11 cuencas marcadas, Jaccard 0.45 a 0.82 según el valor del parámetro). El cuarto es una comparación entre la cascada topológica y el enfoque preexistente de cuenca única a escala nacional que revela una correlación de 0.72, evidenciando que la cascada mide información genuinamente distinta. El sistema integra además un análisis retrospectivo del evento Caquetá 2021 sobre el raster Hansen Global Forest Change v1.12, con conversión rigurosa píxel-hectárea calculada por latitud (0.0774 ha por píxel a 1.5°N). Los resultados se presentan en un dashboard Streamlit multi-pestaña con nueve secciones incluyendo Cascada Hidrológica Caquetá, actualmente probado localmente con streamlit.testing.v1.AppTest sobre las 9 pestañas y pendiente de publicación pública en el momento de esta iteración. SAVIA reporta con honestidad los hallazgos nulos: el test de permutación con 9.999 iteraciones entre cascada e infraestructura devuelve $r=-0.072$ con $p=0.68$, no significativo, lo cual descarta la interpretación de un patrón sistemático y refuerza el uso del sistema como herramienta de priorización de casos críticos concretos, no como modelo predictivo generalizable.

1.2. Identificación del equipo y categoría de participación

El Equipo 66 participa en el nivel Avanzado del Concurso Datos al Ecosistema 2026: IA para Colombia, dentro del reto Desarrollo Sostenible y Medio Ambiente: Usar IA para monitorear deforestación y contaminación hídrica en tiempo real. El equipo está integrado por cuatro analistas de datos con formación técnica complementaria. Bryan Osorio actúa como líder del

módulo de deforestación y responsable del procesamiento raster con Hansen Global Forest Change v1.12, la construcción del grafo dirigido de cuencas HydroBASINS Nivel 7 en Caquetá con el atributo NEXT_DOWN, la asignación de pendiente mediante Copernicus DEM GLO-30 y la integración de las capas vectoriales de infraestructura hídrica IGAC/OSM. Pavel Ramírez lidera el módulo hídrico y estadístico, encargado del cálculo del NSF-WQI, la construcción del score de riesgo explicable con auditoría de colinealidad, el Isolation Forest con contamination='auto' y prueba de sensibilidad, el test de permutación no paramétrico y el análisis de panel con efectos fijos. Brian Acevedo es responsable del dashboard Streamlit multi-pestaña con 9 secciones incluyendo Cascada Hidrológica Caquetá, la integración de los módulos y el despliegue en Streamlit Cloud. Carolina Ramírez lidera la gestión de fuentes de datos abiertos, la documentación metodológica bajo lógica CRISP-ML y la narrativa de presentación. La asignación del nivel Avanzado responde a que el proyecto integra múltiples fuentes de datos abiertos heterogéneas (Hansen GFC, HydroSHEDS HydroBASINS Nivel 7, Copernicus DEM GLO-30, GADM v4.1, infraestructura hídrica IGAC/OSM, IDEAM), combina datos estructurados con datos geospaciales y raster, aplica análisis de grafos hidrológicos con networkx, construye un score explicable con validación de sensibilidad, entrena un Isolation Forest calibrado, realiza test de permutación no paramétrico, ejecuta un análisis retrospectivo del evento Caquetá 2021 y propone un producto funcional con dashboard multi-pestaña. Estas características alinean el alcance técnico con la categoría escogida y demuestran que el nivel de complejidad propuesto corresponde efectivamente al nivel Avanzado del concurso.

1.3. Alineación con el Concurso Datos al Ecosistema 2026

El Concurso Datos al Ecosistema 2026: IA para Colombia busca transformar retos públicos en soluciones concretas mediante el uso estratégico de datos abiertos publicados en datos.gov.co y la aplicación de inteligencia artificial. La convocatoria exige productos funcionales, aplicables a contextos reales, documentados bajo estándares metodológicos, reproducibles por terceros y publicables en repositorios abiertos. SAVIA fue diseñado desde su concepción para responder a cada uno de los seis criterios de evaluación del concurso, adoptando explícitamente un enfoque de profundidad sobre amplitud: el reto sugiere elegir entre profundidad en un caso o superficialidad en muchos, y el equipo priorizó Caquetá como caso de estudio único. En uso de datos abiertos, el sistema consume directamente datasets oficiales del IDEAM publicados en datos.gov.co (Calidad del Agua Superficial 62gv-3857 e IRCA Municipal nxt2-39c3), complementados con el producto raster Hansen Global Forest Change v1.12, las cuencas HydroSHEDS HydroBASINS Nivel 7, el modelo digital de elevación Copernicus DEM GLO-30 desde AWS Open Data, los límites administrativos GADM v4.1 y las capas de infraestructura hídrica IGAC/OSM (210 depósitos, 461 puntos de distribución, 924 ríos), todos documentados con URL canónica y licencia. En uso de tecnologías emergentes e IA, el proyecto integra cuatro componentes analíticos coordinados: análisis de grafo dirigido en networkx para la cascada topológica de cuencas, score de riesgo explicable con validación de sensibilidad, Isolation Forest con contamination='auto' y prueba de sensibilidad, y comparación cascada versus cuenca única sobre 243 estaciones nacionales para dimensionar la aportación técnica del enfoque. En impacto y escalabilidad, la solución identifica cuencas concretas de Caquetá con riesgo combinado (la cuenca #1 acumula 281 puntos de infraestructura hídrica expuesta más

cascada de deforestación alta) y permite su replicación a otras regiones amazónicas mediante el mismo pipeline. En innovación, propone una combinación inédita en el ecosistema colombiano de análisis de cascada topológica, score explicable y validación retrospectiva sobre el evento Caquetá 2021. En rigor técnico, documenta cada decisión bajo la lógica CRISP-ML, reporta hallazgos nulos con honestidad (el test de permutación con $p=0.68$ muestra que no existe un patrón sistemático cascada-infraestructura a nivel departamental) y presenta métricas cuantitativas verificables. En diseño y usabilidad, prioriza la experiencia de usuarios no técnicos mediante un dashboard Streamlit multi-pestaña con nueve secciones y arquitectura backend/frontend separada. Esta sección funciona como una puerta de entrada evaluativa para el jurado.

2. Comprensión del problema

2.1. Contexto ambiental de Colombia

Colombia es uno de los 17 países megadiversos del planeta y alberga aproximadamente el 10% de la biodiversidad mundial. Sin embargo, enfrenta dos amenazas ambientales simultáneas y crónicas que ponen en riesgo sus ecosistemas estratégicos. En el frente forestal, según el Sistema de Monitoreo de Bosques y Carbono del IDEAM, en 2024 Colombia perdió 113.608 hectáreas de bosque natural, un incremento del 35% frente a las 79.256 hectáreas perdidas en 2023, y en las últimas dos décadas el país ha perdido un acumulado de 3.306.393 hectáreas. La Amazonía colombiana concentra cerca del 70% de la deforestación nacional. Caquetá es el departamento amazónico donde SAVIA concentra su análisis: perdió 25.263 hectáreas en 2024 y es la unidad territorial del evento retrospectivo 2020-2022 que el reto GovCamp solicita validar. Meta (21.107 hectáreas en 2024), Guaviare (16.908) y Putumayo (5.443) completan el Arco Amazónico de Deforestación, con causas estructurales comunes: praderización con fines de acaparamiento de tierras, ganadería extensiva no sostenible, cultivos de uso ilícito, desarrollo no planificado de infraestructura vial y minería ilegal. En el frente hídrico, el IDEAM monitorea la calidad del agua superficial mediante la Red de Referencia Nacional de Calidad del Agua, con más de 100 estaciones distribuidas en las principales cuencas. Los reportes oficiales muestran que múltiples corrientes superficiales presentan categorías de calidad regular o mala según el Índice de Calidad del Agua. Ambos problemas son reales, prioritarios, verificables y tienen impacto nacional, regional y territorial, con Caquetá como epicentro simultáneo de deforestación amazónica y de presión sobre las redes hídricas que abastecen comunidades río abajo, lo cual justifica plenamente el desarrollo de una herramienta tecnológica de apoyo a la decisión pública centrada en este departamento como caso profundo.

2.2. Problema público central

El problema central que aborda SAVIA es que las herramientas de monitoreo ambiental existentes tratan cada cuenca o estación como un punto aislado, sin capturar el efecto de red por el cual la deforestación en zonas altas se acumula sobre zonas bajas del territorio. La deforestación en la Amazonía colombiana degrada la calidad del agua y la infraestructura hídrica que abastece a comunidades río abajo, pero los sistemas oficiales existentes no cuantifican la deforestación acumulada aguas arriba de cada punto de interés, lo cual impide priorizar con criterio hidrológico las cuencas donde la degradación forestal upstream converge sobre infraestructura hídrica expuesta. Este problema tiene tres causas estructurales. La primera es la ausencia de análisis topológico hidrológico integrado en las herramientas oficiales: las cifras del SMBYC del IDEAM se reportan por departamento y municipio, no por cuenca hidrográfica con enrutamiento aguas abajo. La segunda es la fragmentación entre datos forestales, hidrográficos y de infraestructura hídrica: los datos existen en Hansen GFC, HydroSHEDS e IGAC pero rara vez se integran en un mismo análisis. La tercera es la limitada capacidad de análisis de priorización: los reportes oficiales tienen carácter agregado y no proveen rankings de cuencas específicas donde la intervención sería más urgente. El

problema, formulado como pregunta operativa, es el siguiente: ¿es posible identificar qué cuencas del Caquetá concentran mayor riesgo combinado de deforestación acumulada aguas arriba, infraestructura hídrica expuesta y pendiente del terreno, para priorizar intervenciones institucionales concretas? Esta formulación es suficientemente concreta para justificar una solución tecnológica específica y suficientemente pública para conectar con un impacto social, ambiental e institucional verificable en el corto plazo, sin prometer generalización nacional que la evidencia estadística disponible en esta iteración no puede sostener.

2.3. Pregunta de negocio o pregunta orientadora

La pregunta orientadora del proyecto es: ¿es posible construir un sistema de bajo costo, basado exclusivamente en datos abiertos y análisis de grafos hidrológicos, que identifique con criterio topológico las cuencas del Caquetá donde la deforestación acumulada aguas arriba converge sobre infraestructura hídrica expuesta, permitiendo priorizar intervenciones institucionales sobre casos concretos verificables? Esta pregunta no busca únicamente evaluar la factibilidad técnica de construir un modelo, sino la viabilidad de diseñar una solución comprensible para usuarios no técnicos, reproducible por terceros, escalable a otras regiones amazónicas por el mismo pipeline metodológico, accionable en términos de toma de decisiones y sostenible en infraestructura gratuita o de costo mínimo. La pregunta también establece un compromiso metodológico explícito con la honestidad estadística: si el análisis revela hallazgos nulos (como efectivamente ocurre con el test de permutación entre cascada e infraestructura hídrica a nivel departamental, con $p=0.68$), el equipo se compromete a reportarlos sin maquillar, presentando el sistema como herramienta de priorización de casos individuales y no como modelo predictivo generalizable. Esta honestidad no debilita el proyecto: al contrario, refuerza su credibilidad técnica ante el jurado y ante los usuarios institucionales que deben decidir dónde intervenir.

2.4. Justificación del proyecto

SAVIA es necesario, pertinente y oportuno por tres razones convergentes. Primero, la deforestación y la contaminación hídrica son fenómenos con consecuencias ambientales, sociales, económicas e institucionales severas: la pérdida de cobertura boscosa libera carbono, fragmenta ecosistemas y desplaza comunidades; la degradación de fuentes hídricas afecta el suministro de agua potable, la salud pública y la productividad agrícola. La detección tardía de estos eventos reduce de manera medible la efectividad de las respuestas públicas. Segundo, los datos abiertos son el camino metodológicamente adecuado para abordar el problema: permiten trazabilidad documentada, transparencia frente a la ciudadanía, reproducibilidad por terceros, auditoría independiente y escalabilidad sin depender de fuentes cerradas que generen costos recurrentes o vínculos con proveedores. Tercero, la inteligencia artificial no se incorpora como elemento decorativo, sino como mecanismo concreto para detectar anomalías estadísticas en parámetros físico-químicos del agua que un analista humano no puede revisar masivamente sobre miles de mediciones, anticipar comportamientos futuros del IRCA municipal con modelos LSTM, identificar el vínculo causal entre deforestación upstream y deterioro hídrico mediante análisis de panel longitudinal con efectos fijos y priorizar zonas críticas con

criterio cuantitativo. La oportunidad se refuerza porque el momento actual combina disponibilidad de datos abiertos suficientes (134.261 registros del IDEAM sobre calidad del agua, 24 años de cobertura raster Hansen Global Forest Change, cartografía hidrológica HydroSHEDS de referencia mundial), infraestructura gratuita de cómputo (Python, Streamlit Cloud, Colab cuando se requiera GPU), modelos open source maduros (scikit-learn, PyTorch) y una agenda pública nacional que prioriza la lucha contra la deforestación a través del Plan Integral de Contención de la Deforestación 2023-2026. La solución contribuye a mejorar la toma de decisiones pública y fortalece el ecosistema nacional de datos abiertos como herramienta de inteligencia colectiva.

3. Objetivos y alcance

3.1. Objetivo general

El objetivo general de SAVIA es construir un sistema de priorización de cuencas hidrográficas en el departamento del Caquetá que integre productos raster globales de pérdida forestal, cartografía hidrológica de referencia mundial, modelos digitales de elevación, capas locales de infraestructura hídrica y análisis de grafos dirigidos para identificar cuencas con riesgo combinado de deforestación acumulada aguas arriba, infraestructura hídrica expuesta y pendiente del terreno, generando un ranking accionable y georreferenciado para autoridades ambientales, comunidades y ciudadanía. El sistema opera sobre 44 cuencas HydroBASINS Nivel 7 aisladas mediante join espacial contra el polígono departamental. La cascada topológica se construye como grafo networkx.DiGraph con arista cuenca hacia cuenca aguas abajo vía el atributo NEXT_DOWN, y para cada cuenca la función nx.ancestors obtiene todas las cuencas ancestro que drenan hacia ella, cuya deforestación reciente (2019-2024) se suma para obtener la variable def_acumulada_reciente_ha. Un score de riesgo explicable combina cascada de deforestación reciente e infraestructura hídrica expuesta con pesos 0.6/0.4 validados mediante grilla de sensibilidad. Un Isolation Forest configurado con contamination='auto' identifica cuencas atípicas con validación de sensibilidad documentada. El análisis retrospectivo del evento Caquetá 2021 se ejecuta sobre el raster Hansen v1.12 con conversión rigurosa píxel-hectárea. Los resultados se presentan en un dashboard Streamlit multi-pestaña con nueve secciones. El objetivo general se compromete explícitamente con la honestidad metodológica: el sistema se presenta como herramienta de priorización de casos individuales, no como modelo predictivo generalizable, en línea con la evidencia estadística disponible.

3.2. Objetivos específicos

Los objetivos específicos del proyecto son siete, cada uno con su forma de medición o evidencia de cumplimiento. Primero, aislar las cuencas HydroBASINS Nivel 7 correspondientes al Caquetá mediante join espacial contra el polígono GADM v4.1, medido mediante el número efectivo de cuencas obtenidas (resultado: 44 cuencas). Segundo, construir un grafo dirigido de la topología hidrográfica del Caquetá con enrutamiento aguas abajo por el atributo NEXT_DOWN, evidenciado por la validación de que 44/44 cuencas están conectadas al grafo sin ciclos y por la identificación de la cuenca con mayor cascada acumulada (HYBAS_ID 6070227530, 277.636 hectáreas de 34 cuencas aguas arriba). Tercero, construir un score de riesgo explicable con dos features ortogonales tras auditoría de colinealidad, evidenciado por la corrección aplicada al haber detectado correlaciones de 1.00 y 0.96 entre variables candidatas iniciales y por la validación de sensibilidad de los pesos con correlación de Spearman entre 0.978 y 1.000. Cuarto, entrenar un Isolation Forest con contamination basado en literatura, evidenciado por el uso de contamination='auto' (paper Liu et al. 2008), el resultado de 11 cuencas marcadas y la prueba de sensibilidad documentada (Jaccard 0.45-0.82). Quinto, ejecutar la validación retrospectiva del evento Caquetá 2021 sobre el raster Hansen filtrando la banda lossyear=21 con conversión píxel-hectárea calculada por latitud (0.0774 ha por píxel a

1.5°N). Sexto, comparar el enfoque de cascada topológica contra el enfoque preexistente de cuenca única a nivel nacional (243 estaciones IDEAM, grafo de 23.783 cuencas SA), evidenciado por la correlación resultante (0.72, cascada aporta información distinta). Séptimo, publicar el dashboard Streamlit multi-pestaña con nueve secciones (incluyendo Cascada Hidrológica Caquetá) con URL pública activa, evidenciado por el enlace publicado en el README (estado actual: probado localmente con streamlit.testing.v1.AppTest, pendiente de push a GitHub y confirmación de URL de Streamlit Cloud).

3.3. Alcance funcional

Desde la experiencia del usuario, SAVIA ofrece un conjunto definido de funcionalidades enfocadas en la priorización de cuencas hidrográficas del Caquetá. El dashboard Streamlit multi-pestaña presenta nueve secciones diferenciadas, incluyendo una pestaña específica de Cascada Hidrológica Caquetá. Las funcionalidades disponibles son: mapa geoespacial del departamento con las 44 cuencas HydroBASINS Nivel 7 coloreadas por score de riesgo combinado, ranking de cuencas priorizadas con la cuenca en el puesto #1 destacada (281 puntos de infraestructura hídrica más cascada de deforestación alta), visualización del grafo dirigido de cuencas con la topología aguas arriba/aguas abajo, exploración de la deforestación acumulada por cuenca en el período 2019-2024, visualización del evento retrospectivo Caquetá 2021 con hectáreas reales calculadas por conversión latitud-específica, comparación entre el enfoque de cascada topológica y el enfoque de cuenca única, consulta detallada de infraestructura hídrica expuesta (210 depósitos, 461 puntos de distribución, 924 ríos) por cuenca, panel de calidad del agua con predicción IRCA municipal 2025 para los municipios del Caquetá, y presentación honesta del test de permutación ($r=-0.072$, $p=0.68$) que documenta que no existe patrón sistemático cascada-infraestructura a nivel departamental. El sistema permite responder preguntas concretas: cuáles cuencas concentran mayor deforestación aguas arriba, dónde la infraestructura hídrica está más expuesta, qué cuencas requieren intervención prioritaria y qué evidencia respalda cada hallazgo. Funcionalidades como cobertura nacional automatizada, integración con sistemas operativos institucionales o predicción en tiempo real no forman parte de esta iteración.

3.4. Alcance técnico

El alcance técnico de SAVIA cubre el flujo completo desde la ingestión de datos hasta la publicación del dashboard, con foco explícito en Caquetá. En la capa de datos, el proyecto consulta o descarga: el raster Hansen Global Forest Change v1.12 desde el bucket público earthenginepartners-hansen (banda lossyear filtrada a 2019-2024 para la métrica reciente y banda 21 aislada para la validación retrospectiva del evento Caquetá 2021), las cuencas HydroSHEDS HydroBASINS Nivel 7 con su atributo NEXT_DOWN para el enrutamiento aguas abajo, el modelo digital de elevación Copernicus DEM GLO-30 desde AWS Open Data (27 tiles que cubren las 44 cuencas del Caquetá, verificados por intersección real de geometría, no solo bbox), el límite administrativo GADM v4.1 nivel 1 para aislar Caquetá, las capas locales de infraestructura hídrica IGAC/OSM (210 depósitos, 461 puntos de distribución, 924 ríos incluyendo 444 clase river) y los datasets IDEAM desde datos.gov.co vía API Socrata (Calidad

del Agua Superficial 62gv-3857, IRCA Municipal nrt2-39c3). En la capa de preparación, se ejecuta limpieza topológica con deduplicación por WKT exacto, reparación de geometrías inválidas con `buffer(0)` y homologación de CRS a EPSG:4326, aislamiento de Caquetá mediante `sjoin` de HydroBASINS Nivel 7 contra el polígono departamental (44 cuencas base), conversión píxel-hectárea calculada por latitud del área de estudio (0.0774 ha/píxel a 1.5°N) en vez de la constante genérica ~0.09 ha citada en la literatura, y filtro temporal `lossyear` a 2019-2024 más banda 21 aislada para el evento retrospectivo. La lectura remota del DEM se hace decimada (ventana 96x96 con `Resampling.average`) por limitación de ancho de banda documentada (0.7 MB/s hacia el bucket S3). En la capa de modelado, se construye un grafo `networkx.DiGraph` con arista cuenca hacia cuenca aguas abajo, se calcula la deforestación acumulada con `nx.ancestors`, se entrena un Isolation Forest de scikit-learn con `contamination='auto'` y 2 features ortogonales tras auditoría de colinealidad, se aplica `log1p` a las features por sesgo (`skew` 1.6-4.2) y se ejecuta test de permutación no paramétrico con 9.999 permutaciones. En la capa de visualización, el dashboard Streamlit multi-pestaña con 9 secciones tiene arquitectura backend/frontend separada: el procesamiento geoespacial pesado corre en notebooks y scripts, mientras que Streamlit solo lee CSV y GeoJSON livianos (geopandas y rasterio no están en el `requirements.txt` de `deploy_streamlit`).

4. Usuarios, beneficiarios y casos de uso

4.1. Stakeholders principales

SAVIA está diseñado para servir simultáneamente a múltiples actores del ecosistema ambiental colombiano. Como stakeholders primarios institucionales, el Ministerio de Ambiente y Desarrollo Sostenible es el actor rector de la política ambiental nacional y el principal beneficiario de un sistema de alertas tempranas que apoye la planeación de intervenciones y el seguimiento al Plan Integral de Contención de la Deforestación 2023-2026; el IDEAM, como entidad técnica productora de los datos base, ve amplificado el valor de su trabajo más allá de los reportes oficiales; y las Corporaciones Autónomas Regionales (Corpoamazonia, CorpoOrinoquia, Cormacarena, Corpomag y demás CARs) son los usuarios operativos más directos del sistema, ya que actúan en territorios específicos y necesitan información oportuna para priorizar visitas, controles y seguimiento. Como stakeholders secundarios, las comunidades indígenas y campesinas que habitan los territorios más afectados por la deforestación (especialmente en la Amazonía) pueden usar el tablero para monitorear sus territorios sin depender únicamente de reportes oficiales tardíos; la Procuraduría y la Contraloría, en sus funciones de control sobre la gestión ambiental, pueden encontrar evidencia objetiva para sus investigaciones; organizaciones de la sociedad civil como Fundación Gaia Amazonas, WWF Colombia y FCDS pueden integrar SAVIA en sus programas de monitoreo independiente; la academia (Instituto Sinchi, Instituto Humboldt, universidades) puede alimentar el sistema con datos adicionales y validar sus resultados; y la ciudadanía general accede al dashboard público para ejercer veeduría informada. El sistema tiene usuarios reales y diversos: su valor no se limita a la presentación de concurso, sino que está pensado para sostenerse y escalar con base en estos múltiples actores.

4.2. Casos de uso prioritarios

Los casos de uso prioritarios de SAVIA se describen siguiendo la estructura usuario-necesidad-entrada-acción-salida. Primero, una autoridad ambiental regional consulta el tablero para identificar municipios con incremento reciente de pérdida de cobertura: ingresa al dashboard, filtra por su jurisdicción departamental, revisa las alertas activas de los últimos 30 días ordenadas por severidad y obtiene un mapa con los polígonos afectados y las hectáreas estimadas, lo cual le permite priorizar visitas de verificación en campo. Segundo, un analista del IDEAM o de una CAR revisa una cuenca hidrográfica para observar tendencia de deterioro del ICA: selecciona la cuenca, escoge una estación, visualiza el histórico de los últimos cinco años y obtiene la predicción a 30 días con banda de confianza más la marca de cualquier anomalía detectada en el periodo reciente. Tercero, una comunidad indígena o campesina consulta si su territorio aparece dentro de una zona con alertas recurrentes: ingresa al dashboard sin necesidad de credenciales, ubica su territorio en el mapa, observa el histórico de alertas en los últimos 12 meses y descarga un reporte básico que puede usar como insumo para dialogar con autoridades. Cuarto, un investigador o periodista descarga o reproduce resultados desde el repositorio público: clona el repositorio, sigue la guía de reproducción y replica los resultados del módulo de deforestación o del módulo hídrico para verificar la metodología o producir un

análisis independiente. Quinto, un jurado del concurso revisa el caso retrospectivo del evento Caquetá 2020-2022: accede a la pestaña de validación retrospectiva del dashboard, ve las hectáreas perdidas por cuenca HydroBASINS Nivel 7 según el filtro banda lossyear=21 del raster Hansen v1.12 con conversión latitud-específica (0.0774 ha/píxel) y comprueba la desagregación por cuenca que las cifras oficiales del SMByC (reportadas solo por departamento) no proveen. Cada caso de uso conecta tecnología con aplicación práctica concreta.

5. Fuentes de datos abiertos

5.1. Estrategia general de datos

La estrategia de datos de SAVIA prioriza fuentes abiertas, oficiales, gratuitas, trazables y reutilizables, en línea con los requisitos del concurso y con el principio de transparencia pública. Las fuentes principales del proyecto en esta iteración con foco Caquetá son siete. Hansen Global Forest Change v1.12 (Universidad de Maryland) aporta la banda lossyear con pérdida forestal anual 2001-2024 a 30 metros de resolución, descargable sin autenticación desde el bucket público earthenginepartners-hansen. HydroBASINS Nivel 7 (HydroSHEDS, Lehner et al. 2008) aporta la topología de cuencas y el atributo NEXT_DOWN para el enrutamiento aguas abajo, con 44 cuencas dentro del Caquetá tras el join espacial. Copernicus DEM GLO-30 (ESA) aporta la elevación para el cálculo de pendiente del terreno como proxy de erosión y sedimentación, accesible sin autenticación desde AWS Open Data en el bucket copernicus-dem-30m. GADM v4.1 Colombia nivel 1 provee el límite administrativo de Caquetá para el aislamiento espacial. Las capas locales de infraestructura hídrica IGAC/OSM aportan 210 depósitos de agua, 461 puntos de distribución y 924 ríos (444 clase river) como insumo del feature `n_infraestructura_agua`. Los datasets IDEAM en `datos.gov.co` (Calidad del Agua Superficial 62gv-3857 e IRCA Municipal nxt2-39c3) aportan series de calidad de agua y riesgo municipal para el módulo hídrico. La selección de cada fuente se evaluó con criterios documentados: cobertura de Caquetá verificada por intersección real de geometría, resolución compatible con el análisis a escala de cuenca, licencia abierta verificada, facilidad de acceso vía API o descarga directa y pertinencia para la pregunta de negocio. Una limitación honesta declarada por el equipo es que las fechas exactas de descarga de cada fuente no están completamente documentadas en la tabla del README, lo cual es un hueco real de trazabilidad que debe cerrarse antes de la entrega final.

5.2. Fuente principal hídrica: IDEAM ICA

Las fuentes del módulo hídrico son dos datasets oficiales del IDEAM publicados en `datos.gov.co` con acceso vía API Socrata usando App Token. El primer dataset es el de Calidad del Agua Superficial Histórica (identificador Socrata 62gv-3857), que contiene series del ICA y NSF-WQI por estación con formato puntual histórico. En esta iteración con foco Caquetá, el dataset se consulta para las estaciones ubicadas en el departamento y sirve como insumo del análisis hídrico complementario. El segundo dataset es el Índice de Riesgo de Calidad del Agua para Consumo Humano (IRCA) municipal anual (identificador Socrata nxt2-39c3), con datos por municipio entre 2007 y 2024. Para SAVIA-Caquetá, este dataset alimenta la predicción de IRCA municipal 2025 para los municipios del departamento. El refresco de estos datos se ejecuta desde el notebook `Data PV/actualizacion_datos.ipynb` mediante la API Socrata con App Token. Una aclaración técnica relevante: el análisis principal de SAVIA en esta iteración se centra en la cascada topológica de cuencas (grafo dirigido con HydroBASINS Nivel 7) y no en la calidad del agua puntual por estación, precisamente porque el enfoque cascada permite capturar el efecto de red que las series puntuales por estación no logran. Los datos IDEAM aportan un contexto complementario y alimentan la sección de calidad de agua e IRCA municipal del dashboard,

pero el núcleo analítico del proyecto es la cascada hidrográfica más el score explicable, no la predicción por estación. Las tareas pendientes para Pavel Ramírez incluyen confirmar las estaciones con cobertura continua superior a tres años para el entrenamiento del LSTM, calcular el porcentaje de datos faltantes por estación y documentar la estrategia de imputación aplicada a cada caso.

5.3. Fuentes principales del módulo forestal: Hansen GFC, HydroSHEDS y SINCHI

Las fuentes principales del módulo de análisis hidrológico-forestal de SAVIA en esta iteración son cuatro. La primera es el producto raster Hansen Global Forest Change v1.12 (Universidad de Maryland), producto de referencia mundial para pérdida forestal a escala global, cobertura 2000-2024 con resolución de 30 metros. La banda principal usada es lossyear (año codificado 0-24 de pérdida forestal). SAVIA aplica dos filtros temporales complementarios: banda 19-24 para la métrica reciente (deforestación acumulada 2019-2024) y banda exacta 21 aislada para el evento retrospectivo Caquetá 2021 solicitado por el reto. La conversión de píxeles a hectáreas se calcula re proyectando la resolución en grados a metros usando la latitud del área de estudio (0.0774 ha/píxel a 1.5°N), evitando el error común de usar la constante genérica 0.09 ha citada en la literatura para latitudes no ecuatoriales. La URL base de descarga es storage.googleapis.com/earthenginepartners-hansen/GFC-2024-v1.12/. La segunda es HydroBASINS Nivel 7 (HydroSHEDS, Lehner et al. 2008), la base de datos hidrológica global de referencia. El equipo eligió el Nivel 7 (área media de cuenca ~5.317 km²) por su compatibilidad con la escala del análisis en Caquetá y por proveer el atributo NEXT_DOWN, esencial para construir el grafo dirigido de enrutamiento aguas abajo. Tras el join espacial contra el polígono GADM del Caquetá, el resultado es de 44 cuencas base sin ciclos, todas correctamente conectadas al grafo topológico. La URL de descarga es hydrosheds.org. La tercera fuente es Copernicus DEM GLO-30 (ESA), modelo digital de elevación a 30 metros de resolución, accesible sin autenticación desde AWS Open Data en el bucket [copernicus-dem-30m](https://aws.amazon.com/opendata/catalog/copernicus-dem-30m/). SAVIA verificó por HEAD request la existencia de los 24 tiles que cubren el bbox de Caquetá (latitud -0.71 a 2.96, longitud -76.31 a -71.32) y expandió a 27 tiles tras verificar la intersección real de geometría (no solo bbox) contra la grilla, garantizando cobertura de las cuencas en los bordes del departamento. La cuarta fuente son las capas locales de infraestructura hídrica IGAC/OSM que aportan al feature n_infraestructura_agua del score: 210 depósitos de agua, 461 puntos de distribución y 924 ríos (444 de clase river). Estas capas están almacenadas en Data PV/unified_*.geojson y son insumo directo del score de riesgo de cada cuenca.

5.4. Fuentes territoriales y de referencia: DIVIPOLA, SMBYC e Inventario Forestal Nacional

Las fuentes territoriales y de referencia del proyecto son tres. La primera es GADM v4.1 Colombia nivel 1, que provee el polígono departamental oficial de Caquetá utilizado para aislar las cuencas HydroBASINS Nivel 7 mediante join espacial con predicado intersects. La URL de descarga es gadm.org, con licencia de uso no comercial compatible con el propósito del

proyecto. La segunda fuente de referencia es el Sistema de Monitoreo de Bosques y Carbono (SMBYC) del IDEAM, que provee las cifras oficiales colombianas de deforestación anual por departamento, utilizadas como fuente independiente de contraste para el análisis retrospectivo del evento Caquetá 2021: mientras el SMBYC reporta la cifra departamental consolidada, SAVIA aporta la desagregación por cuenca HydroBASINS Nivel 7 mediante el filtro banda lossyear=21 del raster Hansen. La URL canónica es ideam.gov.co. La tercera fuente es el Inventario Forestal Nacional del IDEAM, que documenta la composición y estructura de los bosques colombianos y aporta contexto biofísico para interpretar los resultados. En esta iteración con foco Caquetá se agrega también el sistema DIVIPOLA del DANE como fuente complementaria para asignar el código municipal a cada punto o cuenca cuando se cruza el análisis con la predicción IRCA municipal, con acceso vía API Socrata en datos.gov.co.

5.5. Fuentes complementarias ambientales e institucionales

Más allá de las fuentes principales documentadas en las secciones 5.2, 5.3 y 5.4, SAVIA contempla un conjunto de fuentes complementarias que enriquecen el contexto territorial y permiten validación cruzada. En la categoría hídrica se incluyen el DHIME (ideam.gov.co/dhime) con series hidrológicas e hidrometeorológicas del IDEAM, el SIRH (sirh.ideam.gov.co) con información sobre disponibilidad hídrica y gestión integral del agua, SIAC Agua (siac.gov.co) con indicadores nacionales y el portal Datos Abiertos Colombia (datos.gov.co) como catálogo general. En la categoría forestal se incluyen el SMBYC del IDEAM con cifras oficiales, el Geovisor de Bosque y Deforestación en Cifras, los Informes Anuales de Monitoreo de Bosque, el Inventario Forestal Nacional y los Boletines de Alertas Tempranas por Deforestación de Visión Amazonía. En la categoría geocientífica se incluye el Portal de Datos Abiertos del Servicio Geológico Colombiano (datos.sgc.gov.co) con cartografía geológica y amenazas. En la categoría de datos vectoriales sobre Amazonía se incluyen los datos SINCHI publicados en datos.gov.co para períodos 2007-2024 como capa institucional colombiana adicional para cruzar contra Hansen en el análisis retrospectivo. El equipo diferencia claramente las fuentes usadas en el primer prototipo Caquetá (Hansen v1.12, HydroBASINS Nivel 7, Copernicus DEM GLO-30, GADM v4.1, infraestructura IGAC/OSM, IDEAM) de las fuentes complementarias documentadas en la matriz de recolección para potencial uso posterior. Esta clasificación honesta evita generar la percepción de que el equipo promete integrar todo desde el inicio.

5.6. Licencias, trazabilidad y atribución de datos

Cada fuente de datos utilizada en SAVIA se documenta de manera rigurosa para garantizar trazabilidad, transparencia y cumplimiento de las condiciones de uso. El repositorio público del proyecto incluye un archivo dedicado ([docs/fuentes_datos.md](#)) con la información completa por fuente: nombre oficial del dataset, entidad responsable, URL canónica, identificador SODA cuando aplique, fecha de descarga o consulta, versión, licencia, atribución requerida, cobertura temporal y espacial, formato, frecuencia de actualización y uso específico dentro del proyecto. Las atribuciones obligatorias se respetan en los tres tipos de salidas del sistema: en el repositorio cada fuente tiene su cita oficial completa, en el dashboard los créditos aparecen en

un pie de página visible y en cada visualización descargable la fuente se incluye como etiqueta del gráfico o el mapa. Las licencias específicas son: para los datasets IDEAM publicados en datos.gov.co (62gv-3857, hp9r-jxuu, nxt2-39c3) y los datos vectoriales SINCHI y DIVIPOLA, datos abiertos del Estado colombiano publicados bajo los términos de datos.gov.co; para Hansen Global Forest Change, datos abiertos de Google Earth Engine Partners con la atribución requerida Hansen/UMD/Google/USGS/NASA, citando Hansen, M. C., P. V. Potapov, R. Moore, M. Hancher et al. (2013), High-Resolution Global Maps of 21st-Century Forest Cover Change, Science 342, 850-853; para HydroSHEDS HydroBASINS, datos abiertos producidos por WWF y USGS bajo los términos publicados en <https://www.hydrosheds.org>, citando Lehner, B. y Grill, G. (2013), Global river hydrography and network routing. Adicionalmente, el archivo de metadatos del repositorio incluye instrucciones reproducibles de extracción o consulta de cada fuente, lo cual permite que un tercero replique la cadena de datos sin acceso privilegiado. Esta sección responde a las exigencias de transparencia, reproducibilidad y ética del concurso y deja explícito que el proyecto no usa datos cerrados, fuentes sin trazabilidad documentada ni atribuciones omitidas.

6. Preparación, integración y calidad de datos

6.1. Flujo de preparación del módulo forestal

El flujo de preparación del análisis hidrológico-forestal de SAVIA sigue una secuencia documentada de siete pasos ejecutados en Python con rasterio, geopandas y networkx sobre el notebook canónico Data PV/08_modelo_hydrobasins_standalone.ipynb (idempotente por diseño). Primero, limpieza topológica: deduplicación por WKT exacto, reparación de geometrías inválidas con `buffer(0)`, homologación de CRS a EPSG:4326 para las tres capas IGAC de infraestructura hídrica, el límite departamental GADM y las cuencas HydroBASINS. Segundo, aislamiento de Caquetá mediante `sjoin` de HydroBASINS Nivel 7 contra el polígono GADM del departamento con predicado `intersects`, resultado: 44 cuencas base. Tercero, descarga y lectura del raster Hansen v1.12: filtro temporal `lossyear` a banda 19-24 para métrica reciente y banda 21 aislada para el evento retrospectivo Caquetá 2021, con conversión píxel-hectárea calculada por latitud (0.0774 ha por píxel a 1.5°N) en vez de la constante genérica ~0.09 ha, evitando así el error común de reportar conteos de píxeles como si fueran hectáreas. Cuarto, construcción del grafo dirigido `networkx.DiGraph` con arista cuenca hacia cuenca_aguas_abajo vía `NEXT_DOWN`, validando que las 44 cuencas están conectadas sin ciclos. Quinto, cálculo de la deforestación acumulada aguas arriba: para cada cuenca, la función `nx.ancestors` obtiene todas las cuencas ancestro que drenan hacia ella, y la deforestación reciente de esas cuencas se suma en la variable `def_acumulada_reciente_ha`. Sexto, descarga remota decimada del DEM (ventana 96x96 con `Resampling.average`) de los 27 tiles Copernicus DEM GLO-30 que efectivamente intersectan las 44 cuencas (verificado por intersección real de geometría, no solo `bbox`, tras corrección de un error de cobertura inicial). Séptimo, `join` espacial de la infraestructura hídrica IGAC/OSM (210 depósitos, 461 puntos de distribución, 924 ríos) contra cada cuenca para construir la variable `n_infraestructura_agua`. El notebook exporta cinco archivos:

<code>data/processed/alertas_cascada_caqueta.csv,</code>	
<code>outputs/exports/cascada_hidrologica_caqueta.geojson,</code>	
<code>outputs/exports/dashboard_cascada_caqueta.html,</code>	Data
<code>PV/pendiente_cuencas_caqueta.geojson</code>	y Data
<code>PV/modelo_hydrobasins_caqueta_final.geojson.</code>	

6.2. Flujo de preparación del módulo hídrico

El flujo de preparación del módulo hídrico complementario de SAVIA-Caquetá se ejecuta en Python con Pandas y NumPy sobre los datasets IDEAM extraídos vía API Socrata. Primero, descarga desde el notebook Data PV/actualizacion_datos.ipynb con App Token de Socrata del dataset de Calidad del Agua Superficial (62gv-3857), filtrado a las estaciones ubicadas en el departamento de Caquetá según `join` con GADM. Segundo, pivoteo de formato largo a ancho: una fila por par (estación, fecha) y una columna por cada parámetro (oxígeno disuelto, DBO5, pH, turbidez, nitratos, fosfatos, temperatura, coliformes, sólidos suspendidos totales). Tercero, mapeo de nombres de parámetros del IDEAM a nombres canónicos del proyecto. Cuarto, cálculo del NSF-WQI siguiendo la metodología oficial de Brown et al. 1970: cada parámetro se transforma a una puntuación de 0 a 100 mediante las curvas polinómicas oficiales del National

Sanitation Foundation, se aplica la suma ponderada con los pesos oficiales (OD=0.17, coliformes=0.16, pH=0.11, DBO5=0.11, nitratos=0.10, fosfatos=0.10, temperatura=0.10, turbidez=0.08, SST=0.07) y se requiere un mínimo de cuatro parámetros disponibles. Quinto, aplicación de temperatura de referencia por región biogeográfica (Amazonía: 24°C) para evitar sesgos de comparación con estaciones andinas. Sexto, descarga del IRCA municipal (nxt2-39c3) filtrado a los 16 municipios del Caquetá, con normalización min-max usando exclusivamente los años de entrenamiento para evitar fuga de información. El flujo documenta explícitamente sus limitaciones: el parámetro DBO5 tiene 9% de cobertura nacional (similar en Caquetá), lo cual infla el NSF-WQI aproximadamente en 10 puntos para registros que no lo incluyen. Esta limitación se advierte tanto en el dashboard como en la sección Evaluation del CRISP-ML.

6.3. Criterios de calidad de datos

SAVIA define un conjunto de criterios explícitos para evaluar si una fuente o variable es apta para uso en el prototipo. Completitud: porcentaje de datos disponibles frente al total esperado por periodo y estación (umbral mínimo del 80% para incluir una estación en el modelo predictivo). Consistencia: ausencia de contradicciones internas entre variables relacionadas (por ejemplo, valores físicamente imposibles). Cobertura temporal: extensión histórica suficiente para entrenar modelos predictivos (mínimo tres años continuos para LSTM). Cobertura espacial: representatividad geográfica adecuada para el alcance del proyecto (estaciones distribuidas en cuencas amazónicas, no únicamente urbanas). Frecuencia de actualización: compatible con los ciclos del prototipo y declarada de forma transparente al usuario en el dashboard. Granularidad: nivel de detalle espacial y temporal compatible con la pregunta de negocio (resolución de 10 metros para satélite, mensual o trimestral para series hídricas). Estabilidad del identificador de estación o territorio: que el identificador sea persistente y trazable a lo largo del tiempo, para evitar romper series. Disponibilidad de metadatos: presencia de documentación pública sobre la metodología de recolección. Licencia: compatibilidad con uso público y reproducción. Compatibilidad con otras fuentes: posibilidad de cruzar la fuente con otras del proyecto mediante claves comunes (código DIVIPOLA, identificador de estación, polígono). Las estaciones o regiones que no cumplen estos mínimos quedan fuera del prototipo pero se documentan como limitación en la sección Evaluation del CRISP-ML. Esta selección metodológica evita usar datos de forma acrítica y demuestra que el equipo aplica criterios reproducibles, no decisiones arbitrarias.

6.4. Diccionario de datos y metadatos

El repositorio del proyecto incluye un diccionario de datos completo en el archivo docs/diccionario_datos.md, además de los metadatos por fuente en docs/fuentes_datos.md. El diccionario documenta para cada variable usada en el sistema su nombre técnico, descripción funcional, tipo de dato (entero, flotante, fecha, categórico, geográfico), unidad de medida cuando aplique, fuente original con ID SODA si aplica, frecuencia de actualización, reglas de limpieza aplicadas durante el flujo de preparación, valores esperados y rangos válidos, manejo de nulos, y uso específico dentro del modelo o el dashboard. Las variables del módulo hídrico

incluyen identificador de estación, departamento, municipio, cuenca, fecha de muestreo, oxígeno disuelto (mg/L), DBO5, pH, turbidez (UNT), nitratos (mg/L), fosfatos (mg/L), temperatura (°C), coliformes totales (UFC/100ml), sólidos suspendidos totales (mg/L), WQI calculado (0-100) y clase WQI categórica, así como el IRCA municipal anual y la predicción IRCA 2025 con la categoría de tendencia (Mejorando, Estable, Empeorando). Las variables del módulo forestal incluyen identificador de estación, código de cuenca HydroBASINS Nivel 7, área de cuenca en km², porcentaje de pérdida forestal upstream acumulada, pérdida forestal en hectáreas, año, pérdida anual y lags temporales de la pérdida (lag1, lag2, lag3, lag5). El diccionario también documenta los identificadores territoriales: códigos DIVIPOLA del DANE para departamentos y municipios, códigos IDEAM de estación y códigos de cuenca HydroSHEDS jerarquizados (HYBAS_ID). La existencia del diccionario permite reproducir el proyecto desde cero, auditar los resultados frente a las definiciones acordadas y facilitar la lectura por parte del jurado o de cualquier entidad interesada en replicar la metodología. El documento principal entrega un resumen ejecutivo del diccionario y el detalle completo permanece en el repositorio como anexo técnico permanente.

7. Arquitectura de la solución

7.1. Visión general de arquitectura

La arquitectura de SAVIA se organiza en seis capas lógicas con flujo unidireccional desde los datos hasta el usuario, con separación estricta entre backend pesado y frontend liviano. La capa de datos abiertos consulta o descarga: el raster Hansen Global Forest Change v1.12 desde earthenginepartners-hansen (bandas 19-24 y 21 aislada), las cuencas HydroBASINS Nivel 7 con NEXT_DOWN desde hydrosheds.org, el modelo digital de elevación Copernicus DEM GLO-30 desde AWS Open Data (27 tiles para Caquetá), el polígono departamental de GADM v4.1, las capas locales de infraestructura hídrica IGAC/OSM y los datasets IDEAM 62gv-3857 y nxt2-39c3 vía API Socrata. La capa de procesamiento ejecuta el notebook canónico `Data PV/08_modelo_hydrobasins_standalone.ipynb` (idempotente): limpieza topológica, aislamiento de las 44 cuencas del Caquetá, conversión píxel-hectárea calculada por latitud, construcción del grafo dirigido `networkx.DiGraph`, cálculo de `def_acumulada_reciente_ha` con `nx.ancestors`, descarga decimada del DEM y join de infraestructura hídrica. La capa de análisis corre cuatro componentes: el grafo dirigido de cuencas (44 nodos, aristas por NEXT_DOWN), el score de riesgo explicable con 2 features ortogonales `log1p-transformadas` y pesos 0.6/0.4, un Isolation Forest de scikit-learn con `contamination='auto'` y prueba de sensibilidad, y el test de permutación no paramétrico con 9.999 iteraciones. La capa de almacenamiento persiste cinco archivos: `alertas_cascada_caqueta.csv`, `cascada_hidrologica_caqueta.geojson`, `dashboard_cascada_caqueta.html`, `pendiente_cuencas_caqueta.geojson` y `modelo_hydrobasins_caqueta_final.geojson`. La capa de visualización es el dashboard Streamlit multi-pestaña con 9 secciones (incluyendo Cascada Hidrológica Caquetá y NRT) en el repositorio `deploy_streamlit`. La arquitectura backend/frontend garantiza que Streamlit solo lea CSV y GeoJSON livianos, sin ejecutar geopandas ni rasterio en producción (verificado: no están en el `requirements.txt` del deploy). El sistema es idempotente por diseño: re-ejecutar el notebook completo regenera todos los exports.

7.2. Herramientas tecnológicas

Las herramientas tecnológicas de SAVIA se seleccionaron bajo cuatro criterios: bajo costo o gratuidad, facilidad de despliegue, compatibilidad con datos abiertos y posibilidad de replicación por otros equipos. Python es el lenguaje principal para toda la cadena de análisis. Las librerías utilizadas son: Rasterio para lectura y procesamiento de los rasters Hansen y Copernicus DEM (con `Resampling.average` para la lectura decimada del DEM), GeoPandas para manipulación de cuencas HydroBASINS, polígono GADM y capas IGAC/OSM, `networkx` para la construcción del grafo dirigido de cuencas con NEXT_DOWN y el cálculo de `nx.ancestors`, scikit-learn para el Isolation Forest con `contamination='auto'` y `RobustScaler`, NumPy para el test de permutación no paramétrico con 9.999 iteraciones, statsmodels para el análisis de panel con efectos fijos (contexto nacional comparativo), Pandas para las series IDEAM y sodapy para consultar la API Socrata con App Token. La ingesta desde `datos.gov.co` se hace vía API Socrata directa. La descarga de tiles Hansen se hace por HTTPS desde el bucket público de Google Earth Engine

Partners. Las cuencas HydroBASINS Nivel 7 se descargan en formato shapefile. Los tiles Copernicus DEM se leen remotamente desde AWS Open Data con verificación previa por HEAD request. Streamlit es el framework del dashboard multi-pestaña con nueve secciones, con arquitectura backend/frontend separada (deploy_streamlit tiene requirements.txt sin geopandas ni rasterio). GitHub es la plataforma de publicación del repositorio github.com/bryyan1250-dotcom/Forest-Aqua. Los formatos elegidos para los artefactos son abiertos: CSV para tablas, GeoJSON para geometrías vectoriales, GeoTIFF para rasters y Jupyter notebooks para reproducibilidad.

7.3. Repositorio y estructura técnica del proyecto

El repositorio público del proyecto se aloja en GitHub en github.com/bryyan1250-dotcom/Forest-Aqua bajo licencia abierta (MIT o Apache 2.0), con un repositorio raíz para el análisis y un repositorio independiente deploy_streamlit para el dashboard. La estructura de carpetas incluye: Data PV/ con el notebook canónico 08_modelo_hydrobasins_standalone.ipynb (idempotente) y los archivos unified_*.geojson de infraestructura hídrica, notebooks/ con 01_mapbiomas_descarga.ipynb y 02_aoi_sentinel2.ipynb (estado real declarado: solo 2 celdas ejecutadas alguna vez, una con error ModuleNotFoundError _curses), src/processing/ con hydrological_basin.py, upstream_forest.py y topological_cascade.py (script para replicar la cascada a escala nacional con 243 estaciones IDEAM y grafo de 23.783 cuencas SA), data/processed/ con los exports CSV, outputs/exports/ con los GeoJSON generados por el notebook canónico, deploy_streamlit/ como repositorio independiente con el dashboard Streamlit multi-pestaña, docs/ con la documentación CRISP-ML y el archivo de fuentes de datos, y README.md con la tabla de citaciones. El .gitignore excluye data/raw, data/processed, outputs y deploy_streamlit del repositorio raíz. Una limitación honesta declarada por el equipo es que el repositorio raíz no tenía control de versiones hasta esta iteración y que deploy_streamlit tiene cuatro commits locales sin push, lo cual significa que el remoto de GitHub no refleja la pestaña NRT ni la pestaña Cascada Hidrológica ni el fix del bug de pandas 3.0 (Styler.applymap removido en pandas>=3.0, causaba AttributeError en la pestaña IRCA 2025) ni la pendiente/score corregido. Cerrar esta brecha (git push más confirmación de URL de Streamlit Cloud) es acción prioritaria antes de la entrega.

8. Metodología de inteligencia artificial

8.1. Enfoque general de IA

El enfoque de inteligencia artificial y análisis de SAVIA en esta iteración con foco Caquetá es deliberadamente diferenciado por problema y prioriza técnicas defendibles con la evidencia disponible (N=44 cuencas estáticas) sobre la aplicación de modelos más complejos que no encontrarían soporte estadístico suficiente. El primer componente es el análisis de grafo dirigido con networkx: se construye una topología hidrográfica del Caquetá donde cada nodo es una cuenca HydroBASINS Nivel 7 y las aristas siguen el atributo NEXT_DOWN. Para cada cuenca, la función nx.ancestors obtiene el conjunto de cuencas ancestro que drenan hacia ella, y la deforestación reciente (2019-2024) de esas cuencas se agrega en la variable def_acumulada_reciente_ha. Este componente responde al problema de que los sistemas de monitoreo existentes tratan cada cuenca como punto aislado, ignorando el efecto de red. El segundo componente es un score de riesgo explicable con dos features ortogonales tras auditoría de colinealidad (def_acumulada_historico_ha y n_cuencas_aguas_arriba resultaron correlacionadas al 1.00 y 0.96 con def_acumulada_reciente_ha, redundantes por construcción del grafo; corregido a 2 features ortogonales: def_acumulada_reciente_ha y n_infraestructura_agua, con log1p previo por sesgo skew 1.6-4.2). Los pesos 0.6/0.4 se validaron con grilla de sensibilidad (correlación de Spearman entre 0.978 y 1.000, coincidencia top-10 del 67 al 100%). El tercer componente es un Isolation Forest de scikit-learn con contamination='auto' (umbral del paper original Liu et al. 2008, en lugar del 0.15 sin justificación de una versión previa) más prueba de sensibilidad documentada (0.10, 0.15, 0.20, auto con Jaccard 0.45-0.82 respecto a 'auto', 5-11 cuencas marcadas según el valor). El cuarto componente es un test de permutación no paramétrico con 9.999 iteraciones sobre la correlación entre cascada e infraestructura, esencial dado que con N=44 sin panel temporal no aplica una regresión con significancia clásica. Estos componentes no son decorativos: alimentan directamente el ranking de cuencas priorizadas del dashboard y el sistema completo depende de su desempeño.

8.2. Modelo de deforestación

El modelo del módulo de análisis hidrológico-forestal de SAVIA aprovecha el producto raster Hansen Global Forest Change v1.12 ya validado por la Universidad de Maryland como insumo, y construye sobre él dos aportaciones metodológicas: la cascada topológica de cuencas y el score de riesgo explicable. La cascada topológica se construye como un grafo dirigido networkx.DiGraph con arista cuenca hacia cuenca_aguas_abajo vía NEXT_DOWN. Para cada cuenca, nx.ancestors obtiene todas las cuencas ancestro cuya deforestación se agrega en def_acumulada_reciente_ha (banda lossyear 19-24). La cuenca con mayor cascada del Caquetá es HYBAS_ID 6070227530, con 277.636 hectáreas acumuladas provenientes de 34 cuencas aguas arriba. El score de riesgo explicable combina cascada de deforestación reciente e infraestructura hídrica expuesta con pesos 0.6/0.4 validados por grilla de sensibilidad. La cuenca con mayor infraestructura hídrica expuesta (281 puntos: depósitos + distribución) pasó del puesto #6 al puesto #1 del ranking tras la corrección de colinealidad (antes el score estaba

dominado en 92% por volumen de cascada; ahora la correlación score-cascada es 0.52, balance real entre ambas dimensiones). El módulo CNN de clasificación de imagen (ResNet50 transfer learning sobre Sentinel-2 con $\text{IoU} \geq 0.75$) que el reto GovCamp especifica no está completado en esta iteración: el estado real verificado es que notebooks/01_mapbiomas_descarga.ipynb tiene 9 celdas de código con solo 2 ejecutadas alguna vez (una falló con `ModuleNotFoundError _curses`), notebooks/02_aoi_sentinel2.ipynb nunca se ejecutó (0/6 celdas con output), no existe código de entrenamiento CNN en el repositorio y no hay modelo guardado. El bloqueo actual es que Google Earth Engine no autentica: el proyecto configurado (gmail-automation-493601) no tiene el rol `serviceusage.serviceUsageConsumer` necesario, sin el cual no se puede descargar el composite Sentinel-2 requerido. Este módulo queda pendiente hasta resolver el permiso en Google Cloud Console y se reporta abiertamente como brecha del proyecto frente al reto oficial.

8.2.1. Objetivo del módulo

El módulo de análisis hidrológico-forestal de SAVIA tiene como objetivo cuantificar la deforestación acumulada aguas arriba de cada cuenca HydroBASINS Nivel 7 en el Caquetá mediante análisis de grafo dirigido, construir un score de riesgo explicable que combine esa cascada con la infraestructura hídrica expuesta, identificar cuencas atípicas mediante Isolation Forest con `contamination='auto'`, y evidenciar honestamente si existe o no un patrón sistemático departamental mediante test de permutación no paramétrico. Su finalidad operativa es generar un ranking de cuencas priorizadas por riesgo combinado, con la cuenca #1 destacada (281 puntos de infraestructura hídrica más cascada de deforestación alta) como caso de intervención concreta, no como demostración de un patrón generalizable. El módulo se enfoca en priorización de casos individuales, no en modelo predictivo: el $N=44$ cuencas estáticas sin panel temporal no permite entrenar ni validar generalización, y el test de permutación ($r=-0.072$, $p=0.68$) confirma que a nivel departamental no existe correlación cascada-infraestructura más allá del azar. Presentar el sistema como modelo predictivo sería impreciso; presentarlo como herramienta de priorización de casos concretos es lo que la evidencia sostiene.

8.2.2. Área piloto y escalabilidad nacional

El prototipo de SAVIA en esta iteración se concentra explícitamente en el departamento del Caquetá como caso de estudio único, siguiendo la recomendación del propio documento del reto de priorizar profundidad sobre amplitud. El aislamiento se ejecuta mediante `sjoin` de HydroBASINS Nivel 7 contra el polígono GADM del Caquetá, resultado 44 cuencas base sin ciclos. Esta elección responde a tres razones: primera, Caquetá es el caso de demo explícito del reto GovCamp para la validación retrospectiva del evento 2020-2022; segunda, cuenta con datos de infraestructura hídrica IGAC disponibles localmente (210 depósitos, 461 puntos de distribución, 924 ríos) que permiten construir el feature `n_infraestructura_agua` del score; tercera, permite un análisis profundo en un caso concreto en vez de superficial en muchos. El sistema es replicable a otras regiones amazónicas mediante el mismo pipeline metodológico: bastaría reemplazar el polígono GADM del Caquetá por el de otro departamento y re-ejecutar el notebook idempotente `Data/PV/08_modelo_hydrobasins_standalone.ipynb`. El equipo también

construyó `src/processing/topological_cascade.py` para replicar el enfoque cascada a escala nacional (243 estaciones IDEAM, grafo de 23.783 cuencas SA con 2.097 necesarias) como referencia comparativa, evidenciando que la cascada mide información distinta al enfoque de cuenca única (correlación 0.72). La estrategia de escalamiento se centra en tres ejes de profundización futura. Primero, refinamiento estadístico mediante incorporación de panel temporal por cuenca (actualmente el análisis Caquetá es una foto estática). Segundo, desbloqueo del módulo CNN Sentinel-2 mediante resolución del permiso GEE. Tercero, cierre de brechas de trazabilidad (fechas de descarga de fuentes en el README) e integración institucional con Corpoamazonia y las autoridades del Caquetá.

8.2.3. Generación de alertas forestales

Las alertas forestales de SAVIA-Caquetá son la traducción operativa del análisis de cascada topológica a información accionable. Cada alerta corresponde a una cuenca HydroBASINS Nivel 7 del Caquetá (44 en total) y contiene los siguientes atributos: HYBAS_ID de la cuenca, número de cuencas aguas arriba (obtenido con `nx.ancestors`), deforestación acumulada reciente en hectáreas (banda `lossyear` 19-24, conversión latitud-específica), infraestructura hídrica expuesta (`n_infraestructura_agua`: depósitos + puntos de distribución dentro de la cuenca), score combinado con pesos 0.6/0.4, ranking dentro del Caquetá y clasificación como cuenca atípica según Isolation Forest con `contamination='auto'` (11 cuencas marcadas). Las alertas incluyen la evidencia georreferenciada del polígono de la cuenca, la lista de cuencas ancestro que contribuyen a la cascada y el año de pérdida forestal codificado por banda `lossyear`. El sistema no clasifica las alertas por severidad tricolor (verde/amarillo/rojo) sino que presenta el ranking completo ordenado por score, para evitar dar la impresión de una clasificación categórica cuando el análisis es de priorización continua. Cada alerta lleva su nivel de confianza explícito y su limitación específica: se aclara que es una priorización basada en análisis de grafo hidrológico y no una determinación jurídica, y que el test de permutación departamental ($r=-0.072$, $p=0.68$) muestra que no existe patrón sistemático generalizable, por lo cual cada cuenca destacada debe entenderse como caso concreto que amerita verificación en campo, no como parte de una tendencia estadísticamente significativa.

8.2.4. Métricas del módulo forestal

Las métricas del módulo hidrológico-forestal de SAVIA-Caquetá se reportan en tres contextos: el análisis principal de Caquetá con 44 cuencas, la validación retrospectiva del evento 2021 y la comparación cascada versus cuenca única a escala nacional. Las métricas del análisis Caquetá incluyen: cobertura efectiva (44/44 cuencas HydroBASINS Nivel 7 conectadas al grafo sin ciclos), cuenca con mayor cascada (HYBAS_ID 6070227530 con 277.636 hectáreas acumuladas de 34 cuencas ancestro), cuenca #1 en ranking combinado (281 puntos de infraestructura hídrica más cascada de deforestación alta, corrigiendo el ranking dominado 92% por cascada antes de la auditoría de colinealidad), Isolation Forest con `contamination='auto'` (11 cuencas atípicas), grilla de sensibilidad del score (Spearman 0.978-1.000, top-10 robusto 67-100%), test de permutación ($r=-0.072$, $p=0.68$ en 9.999 iteraciones), y correlación score-cascada corregida (0.52, balance entre las dos dimensiones). Las métricas de la

validación retrospectiva del evento Caquetá 2021 sobre banda lossyear=21 aislada incluyen hectáreas por cuenca con conversión latitud-específica (0.0774 ha/píxel) y comparación cualitativa con las cifras departamentales del SMBYC del IDEAM (las diferencias se explican por unidad espacial: SMBYC reporta por departamento, SAVIA por cuenca). Las métricas comparativas cascada vs cuenca única a escala nacional (contexto de referencia, 243 estaciones IDEAM) incluyen correlación 0.72 entre ambos enfoques (evidencia de que la cascada mide información distinta), coeficientes del panel con efectos fijos two-way lag=3 ($p=0.002^{**}$ con cascada versus $p=0.051$ no significativo con cuenca única, mismo signo contraintuitivo positivo) y R^2 dentro de todos los modelos menor a 0.35% (la deforestación explica una fracción mínima de la variación del WQI a esta escala, hallazgo consistente con iteraciones previas). El módulo de pendiente por Copernicus DEM GLO-30 reporta 0/44 cuencas en riesgo de erosión (pendiente $\geq 16^\circ$ y cascada > mediana), con la limitación honesta declarada: la lectura decimada del DEM (ventana 96x96) subestima el relieve local. El intento de leer a resolución nativa se revirtió por limitación de ancho de banda hacia el bucket S3 (~0.7 MB/s, timeout a los 30 min). La corrección requeriría descargar los 27 tiles a disco local (~1.2 GB), factible pero fuera del presupuesto de tiempo de esta iteración.

8.3. Modelo de predicción de calidad del agua

El modelo de predicción de calidad del agua de SAVIA-Caquetá se construye sobre un LSTM (Long Short-Term Memory) en PyTorch como componente complementario del sistema. Su target es el Índice de Riesgo de Calidad del Agua para Consumo Humano (IRCA) municipal anual, publicado por el IDEAM en el dataset nrt2-39c3 de datos.gov.co con serie histórica 2007-2024. La elección del IRCA como target responde a su relevancia directa para política pública. En esta iteración con foco Caquetá, el modelo se entrena sobre la base nacional para aprovechar la señal temporal larga y luego se aplica a los 16 municipios del Caquetá para su predicción 2025, integrando ese resultado en el dashboard multi-pestaña. La arquitectura del LSTM es hidden_size=64, num_layers=2, ventana temporal de cinco años y dropout=0.2. El proceso incluye filtrado de municipios con mínimo 8 años de datos continuos, normalización min-max con años de entrenamiento exclusivamente para evitar data leakage, split temporal estricto (train 2007-2016, val 2017-2018, test 2019-2024), comparación contra baselines (persistencia naïve y XGBoost) y predicción 2025 usando los últimos cinco años como ventana de entrada. Las métricas se reportan por municipio: MAE, RMSE y clasificación tendencial (estable, mejorando, empeorando). Para el conjunto nacional los resultados son 849 municipios con predicción confiable, y para Caquetá específicamente el sistema entrega predicción por cada uno de los 16 municipios del departamento con su clasificación tendencial. Este componente es complementario al núcleo analítico principal de la cascada topológica más score explicable, y aparece como pestaña independiente en el dashboard.

8.4. Modelo de detección de anomalías hídricas

El componente de detección de cuencas atípicas de SAVIA-Caquetá usa Isolation Forest de scikit-learn aplicado sobre las 44 cuencas HydroBASINS Nivel 7 del departamento. Las variables de entrada son las dos features ortogonales del score (def_acumulada_reciente_ha y

n_infraestructura_agua), ya transformadas con log1p por sesgo (skew original 1.6-4.2). La configuración adoptada es contamination='auto' (umbral del paper original de Liu et al. 2008, en lugar del 0.15 sin justificación de una versión previa), n_estimators=200 y muestreo por bootstrap. La lectura honesta del equipo es que el resultado sí es sensible al parámetro contamination: la prueba de sensibilidad documentada muestra que con contamination=0.10 se marcan 5 cuencas (Jaccard 0.45 vs 'auto'), con 0.15 se marcan 7 cuencas (Jaccard 0.64), con 0.20 se marcan 9 cuencas (Jaccard 0.82) y con 'auto' se marcan 11 cuencas (Jaccard 1.00 por definición). No se puede afirmar que el valor del parámetro es irrelevante, y el equipo lo documenta explícitamente en vez de esconderlo. La elección de 'auto' se hace por estar basada en literatura (paper original), no por producir el resultado más conveniente. Las cuencas atípicas identificadas se presentan en el dashboard como parte del ranking prioritario, sin sustituir el score explicable sino como capa complementaria de detección. El sistema documenta explícitamente que una cuenca atípica según el modelo no equivale automáticamente a un caso de riesgo confirmado ni a un incumplimiento normativo, sino a una señal de que sus características se apartan del patrón del conjunto y ameritan verificación adicional.

8.4.1.1. Objetivo del módulo

El módulo hídrico de SAVIA-Caquetá tiene como objetivo complementar el análisis principal de cascada topológica con información sobre la calidad del agua superficial en el departamento, mediante el aprovechamiento sistemático de datos abiertos del IDEAM. El módulo permite visualizar series históricas del NSF-WQI para estaciones del Caquetá, comparar entre estaciones, identificar tendencias positivas o negativas a lo largo del tiempo, y estimar el IRCA municipal 2025 para los 16 municipios del departamento cuando la disponibilidad de datos lo permite. El alcance del módulo es honesto respecto a la frecuencia real de la fuente. El NSF-WQI se construye a partir de campañas de monitoreo trimestrales o semestrales según la estación, no de sensores continuos en tiempo real. En consecuencia, las predicciones se entregan en horizontes compatibles con esa cadencia, y el valor principal del módulo no consiste en pronosticar el WQI hora a hora sino en ordenar registros dispersos en una herramienta única, convertirlos en visualizaciones interpretables y traducirlos en información priorizable. Este módulo complementa (no reemplaza) el núcleo analítico principal del proyecto, que es la cascada topológica de cuencas más el score explicable.

8.4.1.2. Selección de estaciones y cuencas

La selección de estaciones y municipios del Caquetá para el módulo hídrico aplica criterios documentados y reproducibles. Para las estaciones de calidad del agua superficial: cobertura temporal mínima de tres años continuos, porcentaje aceptable de datos faltantes igual o inferior al 20% con estrategia de imputación documentada, disponibilidad de variables suficientes para calcular el NSF-WQI según la metodología oficial y ubicación dentro del polígono departamental de Caquetá. Para los municipios del IRCA: cobertura mínima de ocho años continuos entre 2007 y 2024. Los 16 municipios del Caquetá reciben predicción 2025 individual. La justificación de trabajar con un subconjunto curado en vez del catálogo completo del IDEAM

se documenta abiertamente: en esta iteración, el análisis principal es la cascada topológica sobre las 44 cuencas HydroBASINS, y las estaciones IDEAM aportan un contexto hídrico complementario que se integra al dashboard como pestaña separada. Esta sección evita prometer una cobertura homogénea que la fuente no permite y documenta la elección metodológica.

8.4.2. Predicción de deterioro hídrico

La predicción del deterioro hídrico en SAVIA-Caquetá se construye con un proceso documentado en cinco etapas. Primero, construcción de ventanas temporales de cinco años para cada municipio elegible del Caquetá. Segundo, separación temporal estricta entre entrenamiento (2007-2016), validación (2017-2018) y prueba (2019-2024). Tercero, selección del modelo LSTM con dos capas ocultas, comparado contra baselines (persistencia y XGBoost). Cuarto, evaluación por MAE y RMSE por municipio. Quinto, presentación de resultados en el dashboard: línea observada del IRCA en los últimos años, línea predicha para 2025, categoría tendencial (estable, mejorando, empeorando). El sistema comunica explícitamente que la predicción no es infalible, está condicionada por la calidad y continuidad de la fuente histórica y debe entenderse como estimación apoyada en información pasada. En el contexto de Caquetá, este componente aporta un ángulo específico de política pública (calidad del agua potable municipal) que complementa el análisis principal de cascada de cuencas.

8.4.3. Detección de anomalías hídricas

El componente de detección de cuencas atípicas del Caquetá (44 cuencas HydroBASINS Nivel 7) usa Isolation Forest con `contamination='auto'`, `n_estimators=200` y features log1p-transformadas (`def_acumulada_reciente_ha` y `n_infraestructura_agua`). La configuración se justifica por el paper original de Liu et al. 2008, no por producir el resultado más conveniente. Se ejecuta una prueba de sensibilidad documentada: la comparación entre `contamination=0.10`, `0.15`, `0.20` y `'auto'` produce Jaccard de 0.45, 0.64, 0.82 y 1.00 respectivamente, y el número de cuencas marcadas varía entre 5 y 11. Este análisis se reporta abiertamente: el resultado sí depende del parámetro y esa dependencia se comunica explícitamente al jurado en vez de esconderla. Adicionalmente se ejecuta un test de permutación no paramétrico con 9.999 iteraciones sobre la correlación entre cascada e infraestructura ($r=-0.072$ observado, $p=0.68$ no significativo), que documenta un hallazgo nulo importante: a nivel departamental, la cascada de deforestación y la infraestructura hídrica no están relacionadas más allá del azar. Esto no invalida el score de priorización (la cuenca #1 sigue siendo un caso real que amerita atención), pero sí significa que no existe un patrón generalizable de 'más cascada implica más infraestructura expuesta' en Caquetá. El sistema documenta que las cuencas identificadas son casos concretos de priorización, no evidencia de una tendencia estadísticamente significativa.

9. Validación retrospectiva

9.1. Propósito de la validación

La validación retrospectiva de SAVIA tiene un propósito específico: demostrar que el sistema habría sido útil ante el evento real de deforestación en Caquetá durante 2020-2022 y en particular el pico de 2021. El reto GovCamp especifica explícitamente Caquetá 2020-2022 como caso de validación, y SAVIA lo ejecuta filtrando la banda lossyear=21 del raster Hansen v1.12 y contrastando el resultado con las cifras departamentales del SMByC del IDEAM. No basta con construir un modelo o presentar métricas de sensibilidad: es necesario probar el sistema contra el caso histórico específico solicitado por el reto y evaluar tres cosas: si el módulo detecta el evento conocido, con qué desagregación espacial lo hace (SAVIA lo hace por cuenca HydroBASINS Nivel 7 mientras el SMByC lo reporta por departamento) y cómo se comparan las cifras. Esta validación conecta con dos criterios del concurso: análisis y rigor técnico, porque exige comparación cuantitativa con fuente independiente, e impacto y escalabilidad, porque permite argumentar utilidad práctica evidenciada. La validación es una pieza central de la narrativa del proyecto: ante el jurado no se afirma que el sistema podría haber sido útil sino que se demuestra con la desagregación por cuenca del evento 2021 documentado.

9.2. Diseño metodológico de la validación

La validación retrospectiva de SAVIA se ejecuta sobre el evento de deforestación en Caquetá durante 2020-2022, con foco específico en 2021 según especifica el reto GovCamp. El diseño metodológico sigue cinco pasos. Primero, definición del área de estudio mediante el polígono departamental de Caquetá extraído de GADM v4.1 nivel 1 y la topología de cuencas HydroBASINS Nivel 7 aislada por sjoin (44 cuencas). Segundo, filtro temporal específico del raster Hansen v1.12: banda lossyear=21 aislada para el evento 2021 (frente a la métrica reciente que usa banda 19-24 para 2019-2024). Este filtro específico se introdujo tras corregir el filtro original del notebook que sumaba 2001-2024 sin distinción, lo cual hacía imposible aislar el evento pedido por el checklist. Tercero, cálculo de hectáreas perdidas en 2021 con conversión latitud-específica (0.0774 ha/píxel a 1.5°N) para evitar el error de reportar conteos de píxeles crudos. Cuarto, desagregación de las hectáreas por cuenca HydroBASINS Nivel 7, aportando una granularidad que las cifras oficiales del SMByC (reportadas por departamento) no proveen. Quinto, comparación cualitativa con las cifras del SMByC del IDEAM y del SINCHI para el mismo período, explicando las diferencias estructurales: SMByC usa múltiples fuentes satelitales integradas mientras SAVIA usa Hansen v1.12 sobre Landsat; la unidad espacial de reporte también difiere (departamento vs cuenca hidrográfica). Las diferencias entre las cifras del sistema y las oficiales se documentan con transparencia: no se busca ocultarlas sino explicarlas por diferencias de metodología y unidad espacial. Reportar diferencias con honestidad fortalece el rigor técnico del proyecto.

9.3. Métricas de validación retrospectiva

Las métricas de la validación retrospectiva sobre el evento Caquetá 2021 incluyen seis indicadores complementarios. Primero, hectáreas perdidas estimadas por SAVIA en 2021 mediante filtro banda lossyear=21 del raster Hansen v1.12, con conversión latitud-específica (0.0774 ha/píxel), reportadas tanto para el total departamental como desagregadas por las 44 cuencas HydroBASINS Nivel 7. Segundo, comparación cualitativa con las cifras oficiales del SMByC del IDEAM para el año 2021 y con las cifras de SINCHI para el período 2020-2022 (dataset t235-3ubx en datos.gov.co). Tercero, identificación de las cuencas del Caquetá con mayor concentración de pérdida en 2021, que son las candidatas prioritarias del ranking retrospectivo. Cuarto, análisis de la aportación única de SAVIA: la desagregación por cuenca hidrográfica (44 unidades) frente a la desagregación oficial por departamento (una única cifra) o por municipio (16 municipios). Quinto, consistencia entre el evento retrospectivo 2021 y la cascada reciente 2019-2024: si las cuencas destacadas en el evento aislado 2021 son las mismas o distintas de las destacadas en la ventana reciente, indicador de estabilidad temporal del riesgo. Sexto, evidencia visual: mapas de cuencas del Caquetá coloreadas por hectáreas perdidas en 2021, mostrados en la pestaña Cascada Hidrológica Caquetá del dashboard para verificación visual. La interpretación de los resultados se hace con criterio técnico: las diferencias razonables y documentadas frente a las cifras oficiales se aceptan si se explican las fuentes de variación; el compromiso es la transparencia, no la perfección.

10. Dashboard y experiencia de usuario

10.1. Objetivo del dashboard

El dashboard de SAVIA es el principal producto funcional del proyecto y la interfaz a través de la cual el jurado, autoridades ambientales del Caquetá, comunidades y ciudadanía interactúan con las capacidades del sistema. Se implementa como aplicación Streamlit multi-pestaña con nueve secciones, en el repositorio `deploy_streamlit` del proyecto. Su propósito es convertir datos complejos (rasters Hansen, cuencas HydroBASINS Nivel 7, grafo dirigido `networkx`, capas IGAC/OSM, series IDEAM) en información visual, comprensible y accionable para usuarios sin formación técnica en machine learning, programación o geomática. En consecuencia, prioriza claridad sobre densidad: cada pestaña tiene un propósito único, la navegación es predecible, los indicadores numéricos van acompañados de su unidad de medida y su fuente, los mapas del Caquetá son legibles incluso para usuarios poco familiarizados con la cartografía. Cada alerta lleva su explicación contextual breve. El dashboard responde directamente al criterio de diseño, comunicación y usabilidad del concurso. Estado real declarado: el dashboard ha sido probado localmente sin errores mediante `streamlit.testing.v1.AppTest` sobre las 9 pestañas; sin embargo, tiene 4 commits locales sin publicar contra el repositorio de GitHub del despliegue, y no se ha confirmado aún la existencia de una URL pública activa en Streamlit Cloud. Esta situación se declara honestamente y su resolución (`git push` más confirmación de URL) es acción prioritaria antes de la entrega.

10.2. Vistas principales del tablero

El dashboard de SAVIA se organiza en nueve pestañas del Streamlit multi-pestaña, cada una con una finalidad operativa clara. La pestaña principal es Cascada Hidrológica Caquetá, con el mapa de las 44 cuencas HydroBASINS Nivel 7 del departamento coloreadas por score de riesgo combinado, el ranking de cuencas priorizadas con la cuenca #1 destacada (281 puntos de infraestructura hídrica) y la visualización del grafo dirigido de topología aguas arriba/aguas abajo. La segunda pestaña es la de evento retrospectivo Caquetá 2021 (banda `lossyear=21` aislada), con mapa de hectáreas por cuenca y contraste con cifras oficiales. La tercera pestaña es NRT (near real-time) para el módulo temporal de deforestación planificado. La cuarta es la pestaña de IRCA 2025 con predicción LSTM para los 16 municipios del Caquetá (nota técnica: incluye fix del bug pandas 3.0 al haberse removido `Styler.applymap` que causaba `AttributeError` en versiones previas). La quinta pestaña es la de infraestructura hídrica (210 depósitos, 461 puntos de distribución, 924 ríos) por cuenca. La sexta pestaña es la de calidad del agua superficial NSF-WQI con estaciones IDEAM del Caquetá. La séptima pestaña es la de pendiente por Copernicus DEM GLO-30 (con la limitación honesta declarada: 0/44 cuencas en riesgo de erosión por lectura decimada). La octava pestaña es la de comparación entre cascada topológica y cuenca única (correlación 0.72, evidencia de aportación distinta). La novena pestaña es la de honestidad estadística, donde se presenta abiertamente el test de permutación ($r=-0.072$, $p=0.68$) y la prueba de sensibilidad de contamination (Jaccard

0.45-0.82). Cada pestaña incluye descargas de los archivos generados por el notebook canónico (CSV y GeoJSON), en línea con el principio de trazabilidad de hallazgos.

10.3. Trazabilidad de hallazgos

La trazabilidad de los hallazgos es uno de los principios centrales del diseño de SAVIA. Cada alerta o resultado del sistema lleva asociada la evidencia que la respalda, sin la cual la información sería percibida como opaca o no verificable. Para las cuencas del ranking Caquetá, la evidencia incluye: el polígono exacto de la cuenca en HydroBASINS Nivel 7 (descargable como GeoJSON), el HYBAS_ID único, la lista de cuencas ancestro que contribuyen a la cascada (obtenida con `nx.ancestors`), la deforestación acumulada reciente en hectáreas con conversión latitud-específica, el número de puntos de infraestructura hídrica IGAC/OSM dentro de la cuenca (depósitos + distribución + ríos), el score combinado con pesos 0.6/0.4, la marca de cuenca atípica según Isolation Forest si aplica, y los enlaces a los archivos originales del pipeline (data/processed/alertas_cascada_caqueta.csv, outputs/exports/cascada_hidrologica_caqueta.geojson). Para el evento retrospectivo 2021, la evidencia incluye: banda `lossyear=21` aislada como filtro documentado, hectáreas por cuenca con metodología de cálculo, y comparación con cifras del SMByC. Para las predicciones IRCA municipal, la evidencia incluye: municipio, año, valor observado histórico, valor predicho 2025, MAE del modelo, categoría tendencial. Para el test de permutación, la evidencia incluye: correlación observada, distribución nula con media y desviación estándar, p-valor. Esta trazabilidad transforma el dashboard de una visualización atractiva en una herramienta auditable, donde cada afirmación puede ser verificada, contrastada con otras fuentes y descargada para análisis externo.

10.4. Reportes por territorio

SAVIA permite generar reportes territoriales descargables que resumen el estado ambiental de una unidad geográfica específica: departamento, municipio, cuenca hidrográfica, parque nacional natural o área de interés definida por el usuario. El reporte incluye en su estructura estándar el resumen ejecutivo del estado del territorio (número total de alertas activas, severidad predominante, hectáreas en alerta, estaciones hídricas con tendencia negativa), la lista detallada de alertas forestales con su evidencia, la lista detallada de alertas hídricas con su evidencia, la evolución temporal del último año (gráfica de alertas por mes), las recomendaciones generales de revisión según la severidad (sin pretender sustituir el criterio técnico del usuario) y los enlaces para descargar las evidencias subyacentes en formatos abiertos. En el primer prototipo, los reportes no son automatizados en el sentido de generación periódica programada, sino que se construyen bajo demanda cuando el usuario los solicita desde el dashboard. La estructura de salida está estandarizada para que sea reutilizable: una autoridad ambiental puede usar el reporte como insumo en sus informes internos, una comunidad puede usarlo como soporte para diálogos institucionales, un investigador puede usarlo como evidencia documentada en un análisis territorial y un periodista puede usarlo como base verificable de una nota. Esta capacidad fortalece la dimensión de impacto del proyecto y conecta SAVIA con casos de uso reales más allá de la presentación al concurso.

11. Evaluación técnica del sistema

11.1. Métricas del modelo forestal

Las métricas del módulo hidrológico-forestal de SAVIA-Caquetá se calculan, documentan y reportan en tablas del repositorio del proyecto. Dado que el módulo aprovecha el producto raster Hansen Global Forest Change ya validado por la Universidad de Maryland como insumo y construye sobre él dos aportaciones metodológicas (cascada topológica más score explicable), las métricas se concentran en la consistencia del análisis de grafo y la robustez del score. Las métricas del análisis Caquetá incluyen: cobertura efectiva (44/44 cuencas HydroBASINS Nivel 7 conectadas al grafo sin ciclos), cuenca con mayor cascada (HYBAS_ID 6070227530, 277.636 hectáreas de 34 cuencas ancestro), cuenca #1 en el ranking combinado (281 puntos de infraestructura hídrica + cascada alta), correlación score-cascada corregida (0.52, balance entre las dos dimensiones tras la auditoría de colinealidad), Isolation Forest con contamination='auto' (11 cuencas atípicas), prueba de sensibilidad del parámetro contamination (Jaccard 0.45-0.82 entre 0.10 y 'auto'), grilla de sensibilidad del score (Spearman 0.978-1.000, top-10 robusto 67-100%), y test de permutación ($r=-0.072$, $p=0.68$ en 9.999 iteraciones). Las métricas comparativas cascada vs cuenca única a escala nacional (contexto de referencia, 243 estaciones IDEAM, 23.783 cuencas SA con 2.097 necesarias) incluyen correlación 0.72 y coeficiente two-way FE lag=3 ($p=0.002$ con cascada vs $p=0.051$ con cuenca única, mismo signo positivo contraintuitivo). Las métricas del análisis de pendiente por Copernicus DEM GLO-30 reportan 0/44 cuencas en riesgo de erosión con la limitación honesta declarada por lectura decimada. La sección Evaluation del CRISP-ML documenta metodología y limitaciones. El compromiso del equipo es la transparencia: las diferencias entre las cifras de SAVIA y las oficiales del SMByC se reportan con honestidad y se explican por diferencias de producto raster y de unidad espacial.

11.2. Métricas del modelo hídrico

Las métricas del módulo hídrico complementario de SAVIA-Caquetá se reportan por estación y por municipio, reconociendo que las características de los datos varían y que una única métrica agregada sería engañosa. Las métricas del cálculo del NSF-WQI para estaciones del Caquetá incluyen: número de estaciones con WQI calculado, WQI promedio departamental (con la limitación honesta: DBO5 tiene 9% de cobertura nacional similar en Caquetá, lo cual infla el WQI aproximadamente en 10 puntos para registros sin DBO5), y distribución por clase de calidad. Las métricas del LSTM IRCA para los 16 municipios del Caquetá incluyen: MAE por municipio, RMSE por municipio, clasificación tendencial (estable, mejorando, empeorando) y comparación de desempeño contra los baselines persistencia y XGBoost. Las métricas del contexto nacional (referencia comparativa, no foco principal) incluyen: 849 municipios nacionales con predicción confiable, distribución de tendencias (477 estables, 303 mejorando, 69 empeorando) y evaluación en el período 2019-2024. Las limitaciones estadísticas del análisis de panel con efectos fijos a escala nacional se documentan explícitamente: comparaciones múltiples sin corrección (aproximadamente 30 pruebas de hipótesis entre lags y especificaciones), errores estándar sin cluster por estación (probablemente subestima el error

en presencia de autocorrelación intra-estación), R^2 dentro de todos los modelos menor a 0.35% (la deforestación explica una fracción mínima de la variación del WQI). Estas limitaciones se declaran como brechas metodológicas fuera del alcance de la iteración Caquetá, y se documentan como pendiente si el proyecto vuelve a escala nacional.

11.3. Limitaciones de evaluación

SAVIA reconoce explícitamente las limitaciones de su proceso de evaluación, porque la honestidad metodológica es parte del rigor técnico y porque ocultarlas sería un riesgo para la credibilidad del producto frente a usuarios institucionales y el jurado. Primera limitación, el análisis Caquetá opera sobre $N=44$ cuencas estáticas sin panel temporal, lo cual no permite entrenar ni validar un modelo predictivo en el sentido de generalización: el score es una herramienta de priorización y ranking, no un modelo predictivo, y presentarlo como tal ante el jurado sería impreciso. Segunda limitación, el test de permutación con 9.999 iteraciones sobre la correlación cascada-infraestructura devuelve $r=-0.072$ con $p=0.68$, lo cual documenta abiertamente que a nivel departamental no existe patrón sistemático generalizable, y refuerza el uso del sistema como herramienta de priorización de casos individuales. Tercera limitación, la lectura remota decimada del Copernicus DEM GLO-30 (ventana 96×96 con Resampling.average) subestima sistemáticamente el relieve local; se intentó corregir leyendo a resolución nativa pero se revirtió tras confirmar empíricamente ancho de banda de 0.7 MB/s hacia el bucket S3 con timeout a los 30 minutos; el resultado 0/44 cuencas en riesgo de erosión debe leerse con esa salvedad, y la corrección real requeriría descargar los 27 tiles a disco local (~1.2 GB) fuera del presupuesto de esta iteración. Cuarta limitación, el módulo CNN ResNet50 sobre Sentinel-2 con $\text{IoU} \geq 0.75$ que el reto especifica no está implementado: los notebooks 01 y 02 tienen ejecución mínima (2 y 0 celdas respectivamente), no existe código de entrenamiento ni modelo guardado, y el bloqueo actual es de permisos en Google Cloud Console (proyecto gmail-automation-493601 sin serviceusage.serviceUsageConsumer). Quinta limitación, el dataset IDEAM 62gv-3857 tiene DBO5 al 9% de cobertura nacional, lo cual infla el NSF-WQI aproximadamente en 10 puntos para registros sin DBO5. Sexta limitación, las fechas exactas de descarga de las fuentes no están completamente documentadas en el README (varias filas marcadas 'pendiente'), lo cual es una brecha real de trazabilidad frente al checklist del reto. Séptima limitación, el análisis de panel con efectos fijos a escala nacional (referencia comparativa) usa OLS sobre datos demeaned sin errores estándar robustos por cluster de estación y sin ajuste por comparaciones múltiples, lo cual puede inflar la significancia reportada; estas brechas viven en `run_cascada_nacional.py` y no están resueltas. Estas limitaciones se declaran como parte del rigor técnico, no como debilidad.

12. Impacto, escalabilidad e innovación

12.1. Impacto ambiental esperado

El impacto ambiental esperado de SAVIA se expresa en términos de oportunidad, priorización, transparencia y apoyo a la decisión, no en términos absolutos de hectáreas salvadas, porque esas variables dependen de la acción institucional posterior y no únicamente del sistema técnico. En el frente forestal, una detección más oportuna de pérdida de cobertura boscosa permite a las Corporaciones Autónomas Regionales y a Parques Nacionales Naturales priorizar visitas de verificación en campo, anticipar despliegues operativos en zonas críticas y reducir el tiempo de respuesta institucional ante eventos de tala ilegal o acaparamiento de tierras. En el frente hídrico, la identificación temprana de tendencias de deterioro o de eventos atípicos puede orientar monitoreos adicionales, verificaciones puntuales o intervenciones preventivas antes de que los efectos se consoliden en problemas mayores de salud pública o abastecimiento de agua potable. El sistema vincula directamente con la protección de ecosistemas estratégicos del país: la Amazonía colombiana (foco principal del piloto), la Orinoquía (zona con presiones crecientes de ganadería y minería), el Pacífico (con problemáticas de minería ilegal y deforestación asociadas a economías ilegales) y las cuencas prioritarias del país identificadas por la Política Nacional para la Gestión Integral del Recurso Hídrico. El impacto se materializa cuando el sistema reduce la latencia de detección de eventos de meses a 30 días o menos, cuando los usuarios pueden documentar eventos con evidencia georreferenciada y descargable, y cuando las autoridades regionales pueden priorizar sus recursos limitados sobre las zonas detectadas como críticas por el modelo.

12.2. Impacto social e institucional

El impacto social e institucional de SAVIA se distribuye en cuatro dimensiones complementarias. Primera, facilita el acceso ciudadano a información ambiental que históricamente ha sido técnicamente compleja y geográficamente dispersa, mediante un dashboard público que cualquier persona con conexión a internet puede consultar sin credenciales ni conocimientos especializados. Segunda, promueve la veeduría ciudadana al permitir que comunidades, organizaciones civiles, periodistas e investigadores cuenten con evidencia técnica verificable para sus análisis, denuncias o diálogos con instituciones, fortaleciendo así el ecosistema democrático de información ambiental. Tercera, apoya a autoridades públicas con recursos limitados, especialmente Corporaciones Autónomas Regionales que operan en territorios extensos con personal reducido y que pueden usar las alertas del sistema para priorizar visitas, controles y seguimiento, multiplicando el impacto operativo de su capacidad institucional. Cuarta, fortalece el uso de datos abiertos como herramienta de confianza pública: cuando los datos del IDEAM se convierten en alertas accionables y comprensibles para usuarios no técnicos, los ciudadanos perciben que el Estado produce información útil y que esa información puede ser apropiada y reutilizada por la sociedad. SAVIA contribuye también al cumplimiento del Acuerdo de Escazú firmado por Colombia, que establece compromisos sobre acceso a información ambiental, participación pública en decisiones ambientales y protección de defensores de derechos humanos.

ambientales. La existencia de una plataforma pública, gratuita y reproducible de información ambiental con alertas tempranas es un aporte concreto al cumplimiento de esos compromisos internacionales y a la consolidación de la transparencia ambiental como práctica institucional.

12.3. Escalabilidad nacional

La escalabilidad de SAVIA se orienta explícitamente en tres direcciones a partir del caso profundo Caquetá. Primero, replicación geográfica: el pipeline metodológico (aislamiento por polígono departamental, join de cuencas HydroBASINS Nivel 7, cascada topológica con NEXT_DOWN, score explicable con features ortogonales, Isolation Forest con `contamination='auto'`, test de permutación) es agnóstico al departamento y bastaría reemplazar el polígono GADM del Caquetá por el de otro departamento amazónico (Meta, Guaviare, Putumayo, Amazonas) para replicar el análisis, con el notebook idempotente `Data PV/08_modelo_hydrobasins_standalone.ipynb` como punto de entrada. Segundo, refinamiento estadístico: incorporar panel temporal por cuenca (múltiples años de deforestación y WQI por HYBAS_ID) permitiría pasar de una foto estática a un análisis longitudinal con capacidad predictiva real, resolviendo la limitación de N=44 sin variabilidad temporal. Tercero, desbloqueo del módulo CNN: resolver el permiso de Google Earth Engine (asignar rol `serviceusage.serviceUsageConsumer` al proyecto `gmail-automation-493601` en Google Cloud Console) permitiría implementar el clasificador ResNet50 sobre composites Sentinel-2 que el reto especifica, complementando el análisis raster Hansen con clasificación píxel-a-píxel de mayor resolución (10 m). El equipo también construyó `src/processing/topological_cascade.py` como referencia de escalamiento a 243 estaciones IDEAM y 23.783 cuencas SA (2.097 necesarias), demostrando que el enfoque es técnicamente factible a escala nacional aunque en esta iteración se priorizó la profundidad en Caquetá. La sostenibilidad se sustenta en que toda la infraestructura es gratuita o de costo mínimo (Python, Streamlit Cloud, GitHub, datos abiertos), lo cual permite adopción por entidades públicas con recursos limitados como Corpoamazonia o por equipos comunitarios independientes.

12.4. Innovación del proyecto

La innovación de SAVIA no consiste en el simple hecho de usar inteligencia artificial: las técnicas individuales (grafos dirigidos con networkx, Isolation Forest, test de permutación no paramétrico) son maduras y conocidas. La innovación se encuentra en cinco dimensiones de integración que conjuntamente no tienen equivalente operativo en el ecosistema colombiano de información ambiental. Primera, el análisis de cascada topológica hidrológica: en lugar de tratar cada cuenca o estación como punto aislado (como hacen las herramientas existentes), SAVIA construye un grafo dirigido donde la deforestación de las cuencas altas se enruta aguas abajo mediante NEXT_DOWN, capturando el efecto de red que las herramientas actuales no cuantifican. Segunda, la convergencia hidrológicamente situada de fuentes heterogéneas: rasters globales de pérdida forestal (Hansen v1.12), cartografía hidrológica de referencia (HydroBASINS Nivel 7), modelos digitales de elevación (Copernicus DEM GLO-30), capas locales de infraestructura hídrica (IGAC/OSM) y datasets nacionales IDEAM, cruzados de manera que cada cuenca recibe información multivariada en la unidad espacial

hidrológicamente correcta. Tercera, la validación retrospectiva sobre el caso específico Caquetá 2021 solicitado por el reto, con banda lossyear=21 aislada y conversión latitud-específica píxel-hectárea (0.0774 ha) para evitar el error común de reportar píxeles como hectáreas. Cuarta, el compromiso honesto con hallazgos nulos: SAVIA reporta abiertamente el test de permutación ($r=-0.072$, $p=0.68$) que documenta que a nivel departamental no existe patrón sistemático cascada-infraestructura, transformando lo que sería una debilidad en evidencia de rigor técnico. Quinta, la comparación explícita entre el enfoque de cascada y el enfoque preexistente de cuenca única a escala nacional (correlación 0.72), evidenciando que el nuevo enfoque mide información distinta. La propuesta es innovadora porque convierte datos públicos dispersos en priorización hidrológicamente situada de casos concretos, no porque presuma de algoritmos sofisticados.

13. Ética, legalidad y uso responsable

13.1. Principios éticos

SAVIA se desarrolla bajo seis principios éticos explícitos que orientan el diseño, la implementación y la comunicación del sistema. Transparencia: todas las fuentes, decisiones metodológicas, modelos, métricas y limitaciones se documentan públicamente en el repositorio para que cualquier evaluador pueda auditar las decisiones tomadas. Responsabilidad: el equipo asume responsabilidad por el alcance comunicado del sistema y no promete resultados que la metodología no puede garantizar, por ejemplo, no se afirma que el sistema detecta 'todas' las deforestaciones ni que las predicciones del LSTM son infalibles. Trazabilidad: cada alerta del sistema está respaldada por evidencia descargable que permite verificar la base técnica del hallazgo. Respeto por licencias: cada fuente de datos, librería de software y modelo pre-entrenado se usa bajo los términos de su licencia, con la atribución correspondiente. Reconocimiento de limitaciones: las restricciones de cobertura, frecuencia, resolución y precisión del sistema se documentan abiertamente, no se esconden bajo métricas promedio. No sustitución de la autoridad competente: el sistema no debe usarse para señalar culpables, imponer sanciones, reemplazar procesos oficiales de verificación o sustituir el juicio técnico de las autoridades ambientales con competencia legal. Las alertas son señales analíticas de priorización, no determinaciones jurídicas. Cualquier resultado del modelo debe interpretarse como evidencia sujeta a validación posterior, especialmente en contextos ambientales sensibles donde las decisiones tienen impactos significativos sobre comunidades, ecosistemas y procesos jurídicos en curso. Estos principios se incluyen en el README del repositorio y en la página 'Acerca de' del dashboard para que ningún usuario pueda usar el sistema con expectativas que excedan su alcance real.

13.2. Cumplimiento de licencias y derechos de autor

SAVIA respeta integralmente las licencias de datos, software y fuentes externas usadas en su construcción. Para los datasets IDEAM publicados en datos.gov.co (62gv-3857 e nxt2-39c3), el sistema cita la entidad responsable con URL canónica, identificador Socrata y fecha de consulta cuando esté disponible (limitación declarada: hay filas del README marcadas 'pendiente' respecto a fecha exacta, cierre programado antes de la entrega). Para Hansen Global Forest Change v1.12, el sistema incluye la atribución requerida Hansen/UMD/Google/USGS/NASA y la cita académica oficial Hansen et al. 2013, High-Resolution Global Maps of 21st-Century Forest Cover Change, Science 342, 850-853. Para HydroBASINS Nivel 7 (HydroSHEDS), el sistema cita el producto bajo los términos publicados en hydrosheds.org con la referencia Lehner y Grill 2008 y su condición de libre uso académico. Para Copernicus DEM GLO-30, el sistema cita a la Agencia Espacial Europea y el acceso público sin autenticación desde AWS Open Data. Para GADM v4.1, el sistema respeta la condición de uso no comercial establecida por gadm.org, compatible con el propósito del concurso. Para las capas IGAC/OSM de infraestructura hídrica, el sistema cita las fuentes originales y respeta las condiciones de OpenStreetMap (ODbL) para los elementos derivados de OSM. Las librerías de software utilizadas (Pandas, NumPy, scikit-learn, networkx,

GeoPandas, Rasterio, Streamlit, entre otras) son de código abierto bajo licencias compatibles con uso público. El código del equipo es original y se publica bajo licencia abierta clara (MIT o Apache 2.0) en el repositorio github.com/bryan1250-dotcom/Forest-Aqua.

13.3. Comunicación responsable de alertas

SAVIA implementa cinco prácticas concretas para evitar malas interpretaciones de las alertas y para mitigar el riesgo de que el sistema se use con expectativas que excedan su alcance metodológico. Primera, cada alerta incluye su nivel de confianza explícito, expresado como porcentaje de pérdida acumulada para las alertas forestales y como score de anomalía para las hídricas, de manera que el usuario pueda valorar cuán fuerte es la señal. Segunda, cada alerta indica su fuente de datos primaria (Hansen Global Forest Change cruzado con HydroBASINS Nivel 7 y capas IGAC/OSM para el módulo hidrológico-forestal, datasets IDEAM en datos.gov.co para hídrico) y el periodo exacto al que se refiere, evitando ambigüedades temporales. Tercera, cada alerta lleva su limitación específica: para las forestales se aclara que es una detección sobre raster anual sujeta a verificación en campo y que las cifras pueden diferir de los reportes oficiales del SMByC del IDEAM; para las hídricas se aclara que una anomalía estadística no equivale automáticamente a una contaminación confirmada ni a un incumplimiento normativo. Cuarta, cada alerta incluye una recomendación de verificación cuando aplique: revisar otras fuentes oficiales, consultar a la Corporación Autónoma Regional competente, contrastar con boletines del IDEAM y con reportes del SINCHI cuando se trate de zonas amazónicas. Quinta, el dashboard incluye una sección Acerca de este sistema con un disclaimer claro que explica que SAVIA es una herramienta de apoyo analítico, no una autoridad ambiental, y que no puede usarse como evidencia única para procesos jurídicos, sancionatorios o de denuncia formal. Esta comunicación responsable de las alertas es esencial para que el proyecto sea sostenible en el largo plazo: un sistema que provoque acciones precipitadas, alarmas injustificadas o conflictos sociales basados en interpretaciones erróneas dañaría su credibilidad y la del ecosistema de datos abiertos al que pertenece.

14. Reproducibilidad y publicación abierta

14.1. Publicación del repositorio

El proyecto se publica en un repositorio público en GitHub bajo licencia abierta (MIT o Apache 2.0) que permite a cualquier tercero clonarlo, ejecutarlo, modificarlo y replicarlo. El repositorio incluye el código fuente completo del sistema (scripts de procesamiento, notebooks de entrenamiento, dashboard de Streamlit), los notebooks de análisis exploratorio y validación, los modelos entrenados con sus checkpoints (cuando el tamaño lo permita; en otros casos, las instrucciones de descarga), la documentación CRISP-ML completa en mínimo ocho secciones (Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation, Deployment, Monitoring y Anexos), las instrucciones detalladas de instalación con la lista completa de dependencias, las fuentes de datos documentadas con URL canónica y atribución, los scripts de extracción que permiten reproducir el pipeline de ingestión, los resultados de la validación retrospectiva sobre el evento de deforestación en Caquetá 2020-2022, las capturas y GIFs del dashboard funcionando, la licencia del proyecto, las citas de fuentes y librerías, el enlace activo al dashboard público deployado en Streamlit Cloud y la guía de reproducción paso a paso. Adicionalmente, el enlace del repositorio se registra en la sección de usos del portal de datos abiertos (datos.gov.co), como exige el concurso, para que el sistema quede vinculado a las fuentes que lo alimentan y sea descubrible por usuarios del portal. La publicación abierta no es un componente opcional del proyecto: es una condición habilitante para avanzar en la evaluación del concurso y es un compromiso ético con la reproducibilidad y la apropiación pública del producto desarrollado.

14.2. Guía de reproducción

La guía de reproducción documenta paso a paso el proceso completo que un evaluador o tercero debe seguir para replicar SAVIA-Caquetá. Paso 1, clonar el repositorio desde `github.com/bryyan1250-dotcom/Forest-Aqua` con `git clone`. Paso 2, instalar las dependencias de Python listadas en `requirements.txt` mediante `pip install` (Rasterio, GeoPandas, networkx, scikit-learn, PyTorch, statsmodels, sodapy, Streamlit y sus dependencias). Paso 3, descargar los datasets siguiendo las instrucciones específicas por fuente documentadas en `docs/fuentes_datos.md`: raster Hansen v1.12 desde `earthenginepartners-hansen`, cuencas HydroBASINS Nivel 7 desde `hydrosheds.org`, DEM Copernicus GLO-30 desde AWS Open Data, polígono GADM v4.1 desde `gadm.org`, capas IGAC/OSM ya incluidas en Data PV/, datasets IDEAM vía API Socrata desde `Data PV/actualizacion_datos.ipynb` con App Token. Paso 4, ejecutar el notebook canónico idempotente `Data PV/08_modelo_hydrobasins_standalone.ipynb`, que regenera todos los exports: `data/processed/alertas_cascada_caqueta.csv`, `outputs/exports/cascada_hidrologica_caqueta.geojson`, `outputs/exports/dashboard_cascada_caqueta.html`, `Data PV/pendiente_cuencas_caqueta.geojson` y `Data PV/modelo_hydrobasins_caqueta_final.geojson`. Paso 5, opcionalmente ejecutar `src/processing/topological_cascade.py` para replicar el enfoque a escala nacional como

referencia comparativa. Paso 6, levantar el dashboard localmente con streamlit run deploy_streamlit/app.py para inspeccionar las 9 pestañas. La guía documenta explícitamente que el módulo CNN de Sentinel-2 (notebooks/01_mapbiomas_descarga.ipynb y notebooks/02_aoi_sentinel2.ipynb) no está reproducible en el estado actual: solo 2 y 0 celdas ejecutadas respectivamente, con bloqueo por permisos en Google Cloud Console. Esta transparencia permite que un evaluador entienda qué puede reproducir con éxito y qué depende de resolver el permiso GEE.

14.3. Documentación CRISP-ML

La documentación metodológica de SAVIA sigue la lógica CRISP-ML (Cross-Industry Standard Process for Machine Learning), que organiza el ciclo de vida de un proyecto de inteligencia artificial en fases secuenciales con artefactos verificables. La documentación se estructura en mínimo ocho secciones publicadas en el repositorio en formato Markdown. La sección Business Understanding describe el contexto, el problema público, la pregunta de negocio, los objetivos, los criterios de éxito y los stakeholders del proyecto. La sección Data Understanding documenta las fuentes de datos consultadas, sus características, su calidad, su disponibilidad y sus limitaciones. La sección Data Preparation detalla los flujos de transformación aplicados a los datos antes del modelado, incluyendo limpieza, normalización, imputación y feature engineering. La sección Modeling documenta los modelos entrenados (Isolation Forest sobre parámetros físico-químicos, LSTM en PyTorch para el IRCA municipal y análisis de panel longitudinal con efectos fijos), sus arquitecturas, hiperparámetros, conjuntos de entrenamiento y validación. La sección Evaluation reporta las métricas obtenidas, su interpretación y sus limitaciones. La sección Deployment describe la arquitectura del dashboard, el proceso de despliegue en Streamlit Cloud y la URL pública. La sección Monitoring discute cómo se mantendrá el sistema actualizado y cuáles son los riesgos de degradación del modelo con el tiempo. La sección Anexos incluye el diccionario de datos, las citas completas de fuentes, la documentación del caso de validación retrospectiva sobre el evento de deforestación en Caquetá 2020-2022 y la matriz de cumplimiento del concurso. Los documentos preliminares de Carolina Ramírez ya cubren las versiones iniciales de Business Understanding, fuentes de datos y validación retrospectiva, y se consolidan en la entrega final como una narrativa coherente orientada al concurso, con las secciones técnicas profundizadas por Bryan, Pavel y Brian a medida que avanzan los desarrollos.

15. Resultados esperados y evidencias de entrega

15.1. Entregables técnicos

Los entregables técnicos del proyecto, cada uno con su evidencia verificable, son los siguientes. Primero, el dashboard Streamlit multi-pestaña con nueve secciones (Cascada Hidrológica Caquetá, evento retrospectivo, NRT, IRCA 2025, infraestructura hídrica, NSF-WQI, pendiente, comparación cascada vs cuenca única y honestidad estadística), probado localmente con `streamlit.testing.v1.AppTest`, con acción pendiente de git push a `github.com/bryyan1250-dotcom/Forest-Aqua/deploy_streamlit` y confirmación de URL Streamlit Cloud activa. Segundo, el repositorio principal en GitHub con estructura documentada. Tercero, el notebook canónico idempotente `Data PV/08_modelo_hydrobasins_standalone.ipynb` que genera todos los exports. Cuarto, los cinco archivos exportados: `data/processed/alertas_cascada_caqueta.csv` (ranking de 44 cuencas con score, features y clasificación Isolation Forest), `outputs/exports/cascada_hidrologica_caqueta.geojson` (polígonos de cuencas con métricas), `outputs/exports/dashboard_cascada_caqueta.html` (visualización HTML autónoma), `Data PV/pendiente_cuencas_caqueta.geojson` y `Data PV/modelo_hydrobasins_caqueta_final.geojson`. Quinto, el script `src/processing/topological_cascade.py` para replicar la cascada a escala nacional (243 estaciones IDEAM, 23.783 cuencas SA, 2.097 necesarias) como referencia comparativa. Sexto, los resultados de la validación retrospectiva del evento Caquetá 2021 con banda `lossyear=21` aislada y hectáreas por cuenca. Séptimo, la documentación CRISP-ML completa en el archivo `CRISP_ML.md` con 8 secciones (Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation, Deployment, Monitoring, Riesgos y Limitaciones). Octavo, el archivo `docs/fuentes_datos.md` con las fuentes utilizadas. Noveno, el archivo `caso_validacion_retrospectiva.md` con la documentación del evento 2021. Se declara honestamente el estado real: los notebooks CNN (01 y 02) tienen ejecución mínima y bloqueo por permisos GEE; `deploy_streamlit` tiene 4 commits sin push; las fechas de descarga en el README tienen filas pendientes.

15.2. Entregables para el jurado

El jurado, al evaluar el proyecto, encuentra un conjunto integrado de materiales diseñados para facilitar su revisión y para responder de manera explícita a cada criterio de evaluación. Primero, el documento final del proyecto (este documento), que presenta la narrativa completa: problema, solución, datos, metodología, IA, validación, dashboard, impacto, ética y reproducibilidad. Segundo, la presentación en vivo con el equipo, estructurada para mostrar en menos de diez minutos la pregunta de negocio, la arquitectura, una demo del dashboard multi-pestaña, el caso de validación retrospectiva sobre el evento de deforestación en Caquetá 2020-2022 y la narrativa de impacto. Tercero, la demo del dashboard accesible mediante el enlace activo, donde el jurado puede explorar autónomamente las nueve pestañas del sistema. Cuarto, el repositorio público en GitHub con toda la documentación CRISP-ML, el código y los resultados. Quinto, el caso de validación retrospectiva sobre el evento de deforestación en Caquetá 2020-2022 (con foco en 2021 según especifica el reto), presentado como pieza clave

del rigor técnico del proyecto, con la desagregación por cuenca HydroBASINS Nivel 7 aportada sobre las cifras oficiales del SMByC del IDEAM. Sexto, la explicación de las fuentes de datos abiertos en docs/fuentes_datos.md, que demuestra que el proyecto cumple con el criterio de uso de datos abiertos. Séptimo, las métricas técnicas reportadas por módulo en la sección Evaluation del CRISP-ML. Octavo, la matriz de cumplimiento frente al concurso (sección 19 de este documento), que mapea explícitamente cada criterio de evaluación con la evidencia del proyecto. Noveno, la narrativa de impacto que conecta el sistema con las prioridades ambientales del país y los compromisos internacionales como los ODS y el Acuerdo de Escazú. El conjunto está diseñado para que el jurado encuentre rápidamente qué se hizo, cómo se hizo, con qué datos, qué resultados produjo y por qué importa.

15.3. Criterios de éxito del proyecto

Los criterios de éxito de SAVIA, retomados desde la sección Business Understanding y traducidos a indicadores de cumplimiento verificables, son los siguientes. Éxito técnico del análisis Caquetá: 44/44 cuencas HydroBASINS Nivel 7 conectadas al grafo dirigido sin ciclos, cuenca con mayor cascada identificada (HYBAS_ID 6070227530 con 277.636 hectáreas de 34 cuencas ancestro), score explicable con 2 features ortogonales tras auditoría de colinealidad, Isolation Forest con contamination='auto' y prueba de sensibilidad documentada, test de permutación con 9.999 iteraciones ejecutado y hallazgo nulo reportado abiertamente ($r=-0.072$, $p=0.68$). Éxito de la validación retrospectiva: banda lossyear=21 aislada del raster Hansen v1.12, hectáreas por cuenca calculadas con conversión latitud-específica y comparadas con cifras oficiales del SMByC. Éxito funcional del dashboard: nueve pestañas operativas probadas con streamlit.testing.v1.AppTest, con acción pendiente de git push y confirmación de URL Streamlit Cloud. Éxito de reproducibilidad: notebook canónico idempotente Data PV/08_modelo_hydrobasins_standalone.ipynb, exports en formatos abiertos, repositorio GitHub github.com/bryyan1250-dotcom/Forest-Aqua con licencia abierta, documentación CRISP-ML con 8 secciones. Éxito de honestidad metodológica: brechas declaradas abiertamente (módulo CNN no completado por bloqueo GEE, deploy_streamlit sin push, fechas de descarga pendientes en el README, limitación de lectura decimada del DEM, N=44 estático sin panel temporal), y hallazgos nulos reportados sin maquillar (test de permutación $p=0.68$, R^2 menor a 0.35% en el panel nacional). Éxito de impacto esperado: conexión con ODS 13 y 15, aportación de desagregación por cuenca a la información oficial que se reporta solo por departamento, y ranking de cuencas priorizadas con la cuenca #1 destacada como caso concreto de intervención. Esta lista sirve como cierre evaluativo antes de la presentación al jurado y permite confirmar que cada compromiso tiene su correspondencia en los entregables del repositorio y del dashboard.

Matriz de cumplimiento frente al concurso

19.1. Uso de datos abiertos

SAVIA responde al criterio de uso de datos abiertos (20 puntos) mediante la integración rigurosa y documentada de fuentes principales del Estado colombiano y de organismos

internacionales reconocidos, todas abiertas, oficiales y trazables. Las fuentes principales del módulo hidrológico-forestal en la iteración Caquetá son cuatro: el raster Hansen Global Forest Change v1.12 (Universidad de Maryland, dominio público, descarga por HTTPS desde earthenginepartners-hansen), las cuencas HydroBASINS Nivel 7 (HydroSHEDS/Lehner et al. 2008, con atributo NEXT_DOWN esencial para el grafo dirigido, 44 cuencas en Caquetá tras join espacial), el modelo digital de elevación Copernicus DEM GLO-30 (ESA, 27 tiles verificados por intersección real de geometría desde AWS Open Data) y las capas locales IGAC/OSM de infraestructura hídrica (210 depósitos, 461 puntos de distribución, 924 ríos). Las fuentes territoriales son GADM v4.1 Colombia nivel 1 (uso no comercial) para el aislamiento de Caquetá y DIVIPOLA del DANE (vcjz-niiq y xaxy-8nri) para asignación municipal. Las fuentes del módulo hídrico complementario son dos datasets del IDEAM

19.2. Uso de tecnologías emergentes e inteligencia artificial

SAVIA responde al criterio de uso de tecnologías emergentes e inteligencia artificial (20 puntos) mediante la integración coordinada de tres componentes analíticos que constituyen el núcleo del sistema y no un componente accesorio. El primero es el Isolation Forest entrenado en scikit-learn (configuración `contamination=5%`, `n_estimators=200`) sobre los nueve parámetros físico-químicos del NSF-WQI, con entrada normalizada por RobustScaler, salida de score de anomalía continuo y resultado documentado de 340 anomalías de 6.831 registros (5.0%) con concentración en Cundinamarca (10.7%), Santander, Boyacá, Huila y Meta. El segundo es el LSTM implementado en PyTorch (`hidden_size=64`, `num_layers=2`, ventana temporal de cinco años) entrenado con split temporal estricto sin data leakage (entrenamiento 2007-2016, validación 2017-2018, prueba 2019-2024) sobre el IRCA municipal anual del IDEAM, con salida de predicción 2025 para 849 municipios clasificados en tendencia estable (477), mejorando (303) o empeorando (69) y comparación contra baselines persistencia naïve y XGBoost para verificar que la complejidad aporta valor. El tercero es el análisis de panel longitudinal con efectos fijos (one-way y two-way demeaning) que opera sobre 2.913 pares estación-año para evidenciar el vínculo causal entre deforestación upstream y deterioro de calidad del agua, con coeficiente one-way FE lag de dos años de -1.207 ($p=0.043$) estadísticamente significativo y en la dirección esperada. Cada componente tiene entradas, salidas, métricas y uso operativo explícito dentro del flujo de generación de alertas e información. La IA no se usa de forma superficial ni decorativa: alimenta directamente las alertas y predicciones que aparecen en el dashboard, no se podría obtener el producto sin estos componentes y el rendimiento del sistema completo depende de su desempeño documentado. Adicionalmente, el proyecto incorpora prácticas de IA responsable: documentación de limitaciones (DBO5 al 9% de cobertura, modelos two-way FE no significativos por horizonte temporal corto), comunicación responsable de alertas, trazabilidad de cada decisión del modelo y reconocimiento explícito de los límites del alcance. Esta combinación de componentes diferenciados, documentados, evaluados y responsablemente comunicados constituye un uso sustantivo de IA, alineado con el nivel Avanzado del concurso.

19.3. Impacto y escalabilidad

SAVIA responde al criterio de impacto y escalabilidad (20 puntos) en tres dimensiones complementarias. En impacto ambiental, el sistema aporta una desagregación por cuenca hidrográfica del análisis de deforestación que las cifras oficiales del SMByC (reportadas por departamento) no proveen, y permite priorizar intervenciones institucionales sobre las 44 cuencas del Caquetá con criterio hidrológico integrado (cascada de deforestación aguas arriba + infraestructura hídrica expuesta), fortaleciendo la capacidad de respuesta institucional en el Arco Amazónico de Deforestación que el concurso identifica como prioritario. En impacto social e institucional, el dashboard público gratuito permite veeduría ciudadana sobre las cuencas priorizadas del Caquetá, apoya a Corpoamazonia y a las autoridades del departamento con recursos limitados, facilita el acceso a información ambiental por parte de comunidades indígenas y campesinas del Caquetá y contribuye al cumplimiento del Acuerdo de Escazú firmado por Colombia. En escalabilidad, el sistema crece en tres direcciones sin requerir rediseño arquitectónico: replicación geográfica a otros departamentos amazónicos (Meta, Guaviare, Putumayo, Amazonas) mediante reemplazo del polígono GADM y re-ejecución del notebook idempotente `Data PV/08_modelo_hydrobasins_standalone.ipynb`, refinamiento estadístico mediante incorporación de panel temporal por cuenca para pasar de foto estática a análisis longitudinal, y desbloqueo del módulo CNN Sentinel-2 mediante resolución del permiso GEE. El equipo también construyó `src/processing/topological_cascade.py` como referencia de escalamiento a 243 estaciones IDEAM y 23.783 cuencas SA, demostrando que el enfoque es técnicamente factible a escala nacional aunque en esta iteración se priorizó explícitamente la profundidad en Caquetá. La sostenibilidad se sustenta en que toda la infraestructura es gratuita o de costo mínimo.

19.4. Innovación y creatividad

SAVIA responde al criterio de innovación y creatividad (15 puntos) no por usar IA como tecnología novedosa en abstracto, sino por la combinación específica de capacidades que conjuntamente no tienen equivalente operativo en el ecosistema colombiano actual de información ambiental. La novedad se concentra en cinco integraciones simultáneas. Primera, el análisis de cascada topológica hidrológica mediante grafo dirigido `networkx` con atributo `NEXT_DOWN` sobre las 44 cuencas HydroBASINS Nivel 7 del Caquetá, capturando el efecto de red que las herramientas oficiales (que tratan cada cuenca como punto aislado) no cuantifican. Segunda, la convergencia hidrológicamente situada de fuentes heterogéneas: rasters globales de pérdida forestal (Hansen v1.12), cartografía hidrológica (HydroBASINS Nivel 7), modelo digital de elevación (Copernicus DEM GLO-30), capas locales de infraestructura hídrica (IGAC/OSM) y datasets IDEAM, cruzados de manera que cada cuenca recibe información multivariada en la unidad espacial hidrológicamente correcta

19.5. Análisis y rigor técnico

SAVIA responde al criterio de análisis y rigor técnico (15 puntos) en seis dimensiones documentadas. Primera, la metodología CRISP-ML organiza todo el ciclo de vida del proyecto en ocho secciones documentadas en el archivo `CRISP_ML.md` del repositorio (Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation, Deployment,

Monitoring y Riesgos/Limitaciones). Segunda, la validación retrospectiva sobre el evento de deforestación en Caquetá 2020-2022 (con foco específico en 2021 según especifica el reto GovCamp) se ejecuta con banda lossyear=21 aislada del raster Hansen v1.12 y con conversión latitud-específica píxel-hectárea (0.0774 ha/píxel a 1.5°N), aportando desagregación por cuenca HydroBASINS Nivel 7 que las cifras oficiales del SMByC (reportadas por departamento) no proveen. Tercera, las métricas del análisis Caquetá están definidas, calculadas y reportadas: cobertura efectiva 44/44 cuencas HydroBASINS Nivel 7 conectadas al grafo sin ciclos, cuenca con mayor cascada identificada (HYBAS_ID 6070227530 con 277.636 hectáreas de 34 cuencas ancestro), Isolation Forest con contamination='auto' y 11 cuencas atípicas, grilla de sensibilidad del score (Spearman 0.978-1.000, top-10 robusto 67-100%) y test de permutación con 9.999 iteraciones ($r=-0.072$, $p=0.68$ no significativo, hallazgo nulo reportado abiertamente). Cuarta, la documentación de datos incluye criterios explícitos de calidad y descarta estaciones y variables que no cumplen los mínimos. Quinta, el control de calidad incluye validación de rangos físicos, detección de duplicados por WKT exacto, reparación de geometrías inválidas con buffer(0), homologación de CRS a EPSG:4326, imputación documentada y separación temporal entre entrenamiento, validación y prueba para el LSTM. Sexta, el análisis de limitaciones se hace explícitamente en la sección Evaluation del CRISP-ML, donde se documentan las diferencias estructurales con las fuentes oficiales, la limitación de lectura decimada del DEM (0.7 MB/s hacia AWS S3), el estado real del módulo CNN no completado por bloqueo GEE, el N=44 estático sin panel temporal y las brechas de trazabilidad en el README. El proyecto no construye una demo aislada: documenta decisiones, supuestos, métricas, limitaciones y hallazgos nulos con transparencia.

19.6. Diseño, comunicación y usabilidad

SAVIA responde al criterio de diseño, comunicación y usabilidad (10 puntos) en cuatro dimensiones. Primera, el dashboard se diseña para usuarios no técnicos con nueve pestañas claramente diferenciadas (Cascada Hidrológica Caquetá, evento retrospectivo Caquetá 2021, NRT, IRCA 2025, infraestructura hídrica, NSF-WQI, pendiente por Copernicus DEM, comparación cascada vs cuenca única y honestidad estadística), navegación lineal y predecible, mapas legibles con etiquetas grandes y colores accesibles, series de tiempo con explicaciones contextuales y alertas con texto explicativo que responde a las preguntas básicas qué pasó, dónde y por qué importa. Segunda, las pruebas de usabilidad con al menos una persona externa al equipo se ejecutan en la semana 3 del proyecto, antes de la presentación final, para detectar problemas de comprensión y ajustarlos. Tercera, la narrativa del proyecto se construye para que el jurado entienda rápidamente, en menos de diez minutos de presentación, el problema (fragmentación entre datos forestales, hidrográficos y de infraestructura hídrica más ausencia de análisis topológico), la solución (SAVIA con cascada hidrológica sobre 44 cuencas del Caquetá), la evidencia (validación retrospectiva sobre el evento Caquetá 2020-2022 con banda lossyear=21 aislada y desagregación por cuenca) y el impacto (priorización accionable para autoridades del Caquetá y ciudadanía). Cuarta, todos los artefactos públicos del proyecto (repositorio, dashboard, documento) priorizan la claridad sobre la densidad: el README incluye GIF demostrativo, el dashboard incluye una página 'Acerca de' que explica el sistema en lenguaje accesible y el documento usa estructura jerárquica con

títulos descriptivos y párrafos enfocados. El diseño y la comunicación no se conciben como un componente cosmético al final del proyecto, sino como una dimensión de calidad integrada en cada decisión, desde la arquitectura técnica hasta la presentación final al jurado.